Deep Learning

01. 딥러닝 개요

강사 양석환

딥러닝 감잡기

딥러닝 적용 개념 살펴보기

- 여러가지 딥러닝 관련 개념, 지식과 이론, 모델 등을 살펴보았으나 딥러닝을 어떻게 사용하라는 것인지?
- 간단한 예시를 통해 딥러닝 적용의 개념을 이해하자

잘 익은 귤 분류하기

- 문제 제시
  - 2개의 상자가 있음
    - 잘 익은 귤 상자
    - 덜 익은 귤 상자
  - 분류 주체
    - 일단 사람이 먼저 분류하자
    - 사람이 분류하는 내용을 보면서 감을 잡고, AI 머신을 이용해서 분류하자
      - AI 머신에서는 프로그램을 작성해서 분류하게 된다

잘 익은 귤 분류하기

- 사람의 분류 과정
  - 귤을 잔뜩 모아 놓고 분류를 시작함
  - 잘 익은 귤과 덜 익은 귤을 각각 상자에 나눠 넣음 □ 귀찮음
  - 뭔가 고정된 분류 기준이 있으면 좋겠다...
    - 잘 익은 귤을 보니 대체로 크고 덜 익은 귤은 작더라
    - 대충 크기를 재어보니 잘 익은 귤은 지름이 7.5cm 이상이다.
  - 귤의 지름이 7.5cm인 것을 기준으로 분류하자 □ 프로그램 작성

    → AI 머신의 분류 작업으로...

잘 익은 귤 분류하기

- AI 머신의 분류 과정
  - if size > 7.5 then right_box else left_box

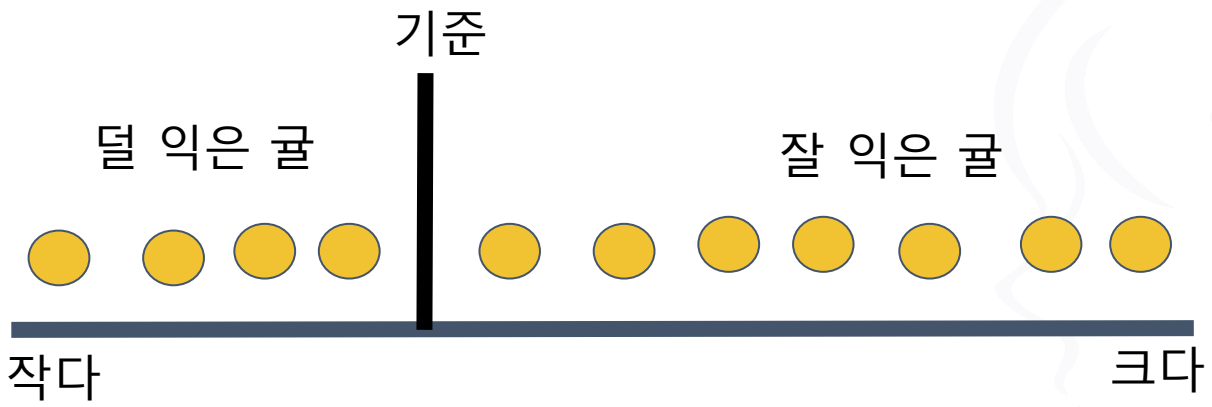

잘 익은 귤 분류하기

- AI 머신의 작업결과를 보고 있으니...
  - 가끔씩 7.5cm 미만의 귤 중에 잘 익은 것이 나온다.
  - 가끔씩 7.5cm 이상의 귤 중에서도 덜 익은 것이 나온다.
  - 하드 코딩한 AI 머신의 프로그램을 바꿔야할 것 같다....

    → 하드 코딩한 기준도 스스로 찾아내도록 하고 싶다..

잘 익은 귤 분류하기

- **AI 머신의 작업 내용**
  - **귤의 분류 기준 찾기**

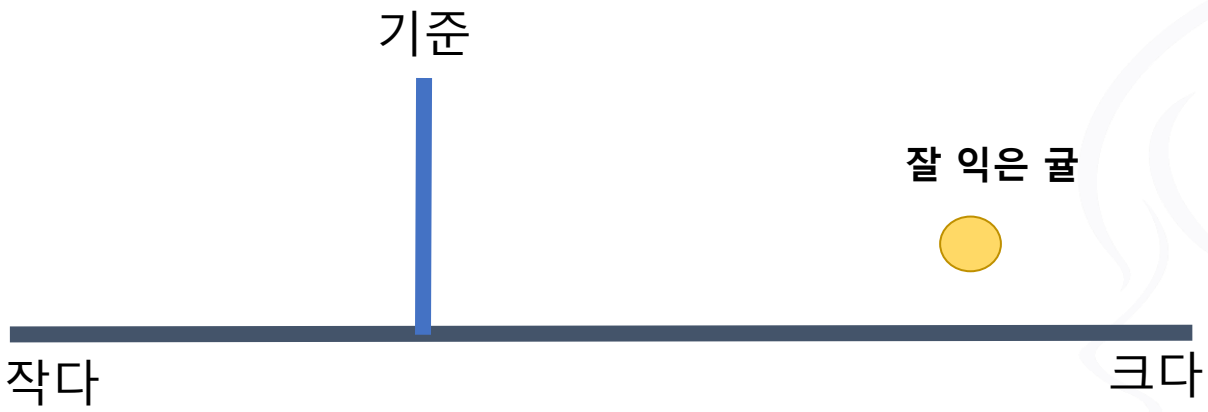

잘 익은 귤 분류하기

- AI 머신의 작업 내용
  - 귤의 분류 기준 찾기

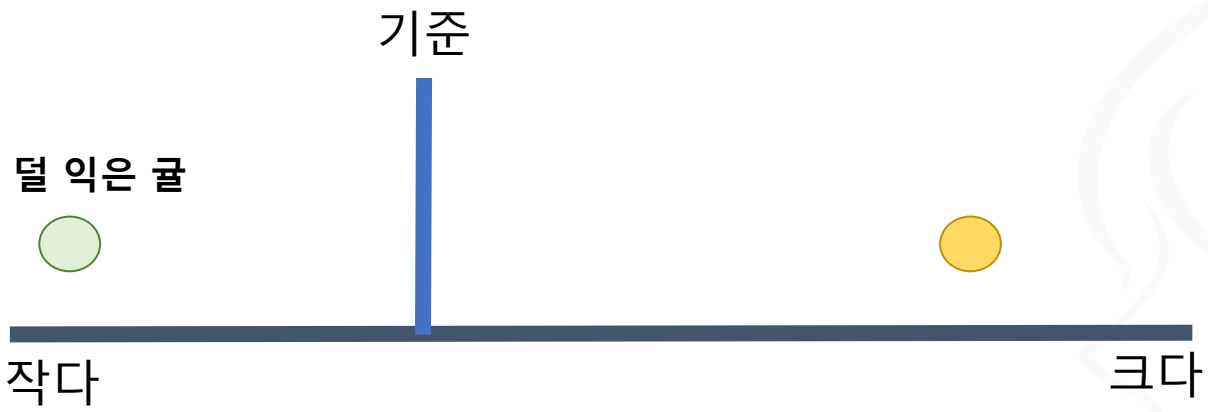

잘 익은 귤 분류하기

- AI 머신의 작업 내용
  - 귤의 분류 기준 찾기

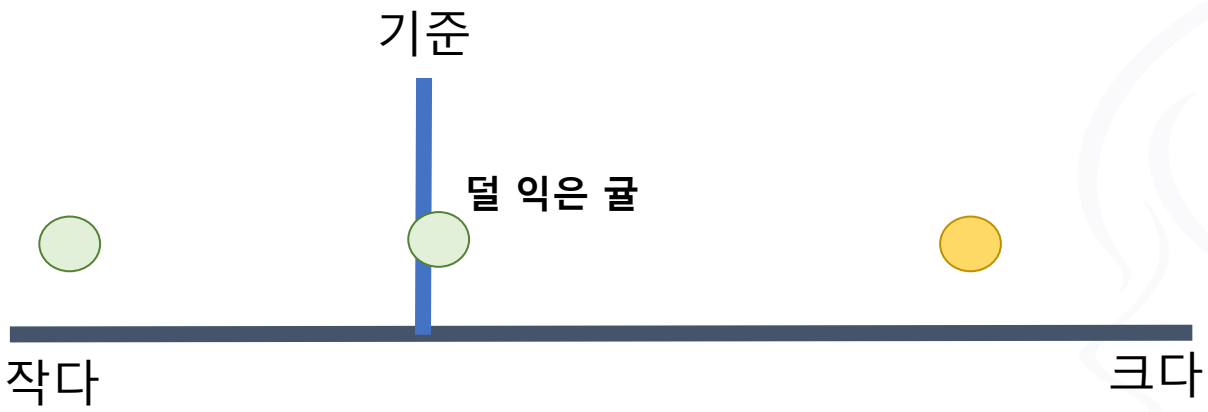

잘 익은 귤 분류하기

- AI 머신의 작업 내용
  - 귤의 분류 기준 찾기

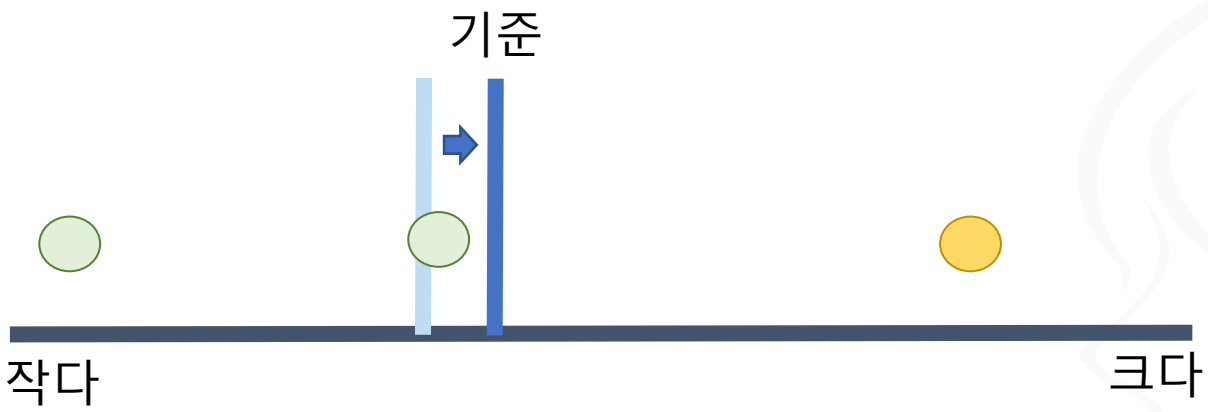

잘 익은 귤 분류하기

- AI 머신의 작업 내용
  - 귤의 분류 기준 찾기

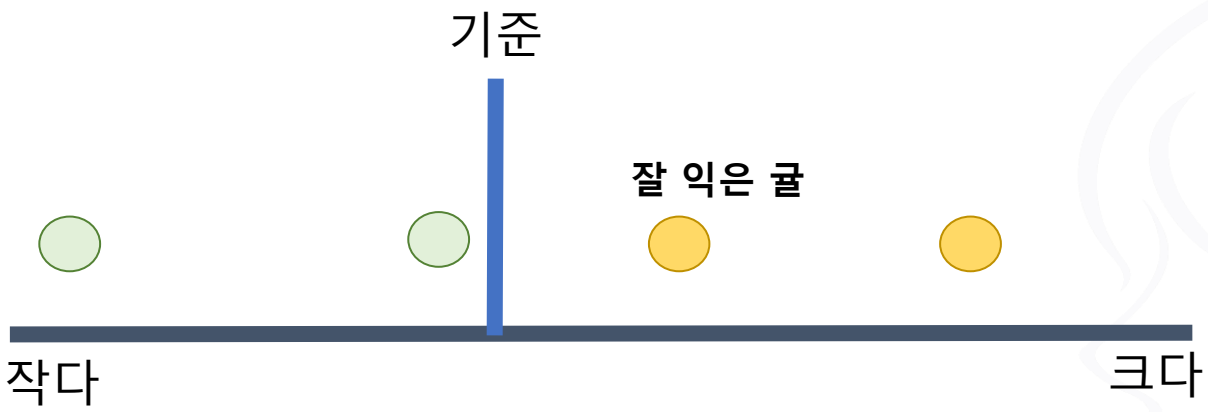

잘 익은 귤 분류하기

- AI 머신의 작업 내용
  - 귤의 분류 기준 찾기

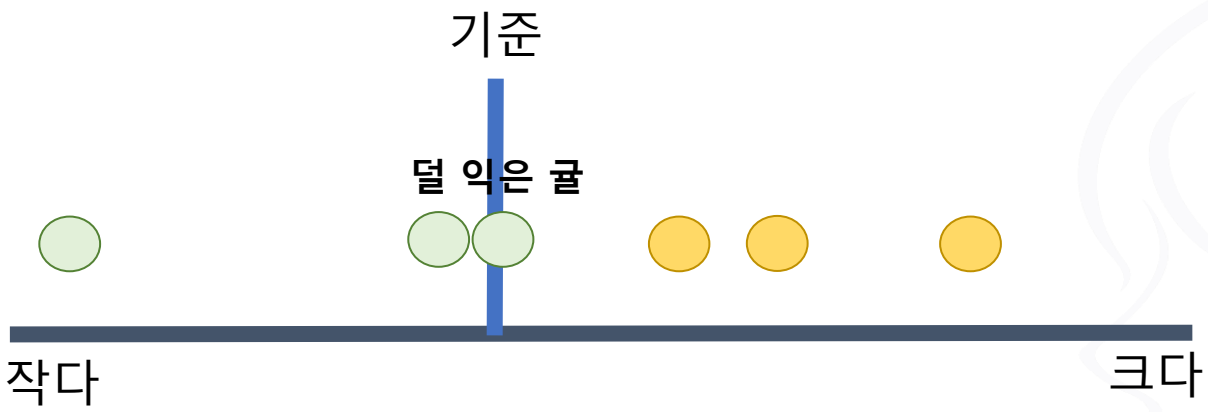

잘 익은 귤 분류하기

- AI 머신의 작업 내용
  - 귤의 분류 기준 찾기

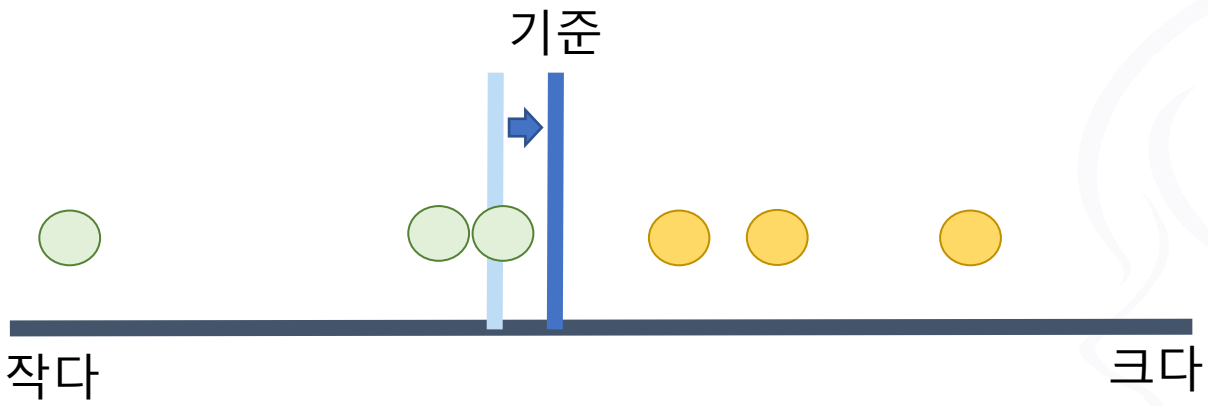

잘 익은 귤 분류하기

- AI 머신의 작업 내용
  - 귤의 분류 기준 찾기

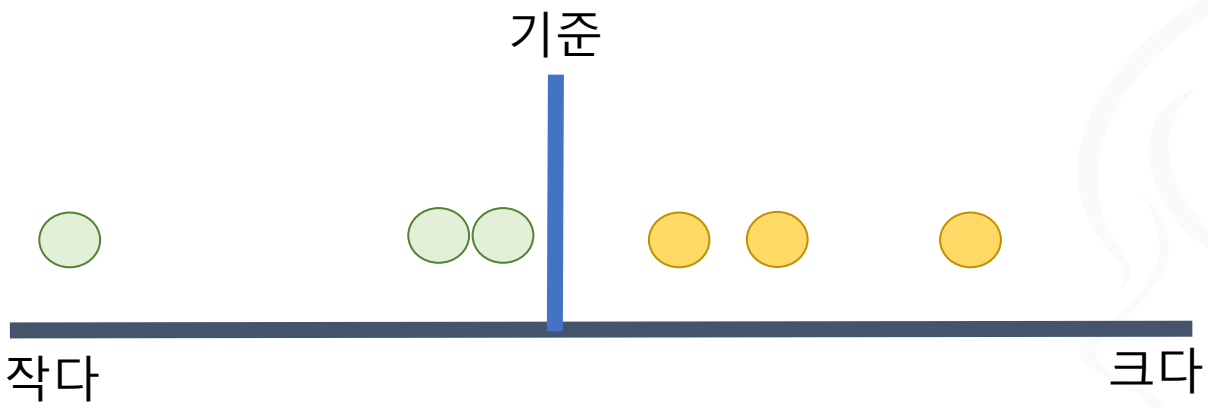

잘 익은 귤 분류하기

- AI 머신의 작업 내용
  - 귤의 분류 기준 찾기

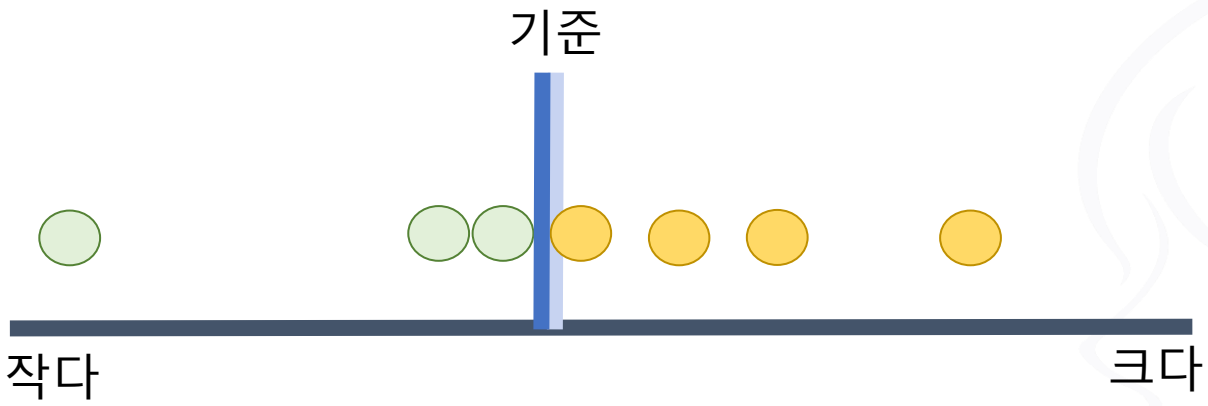

잘 익은 귤 분류하기

- AI 머신의 작업 내용
  - 귤의 분류 기준 찾기

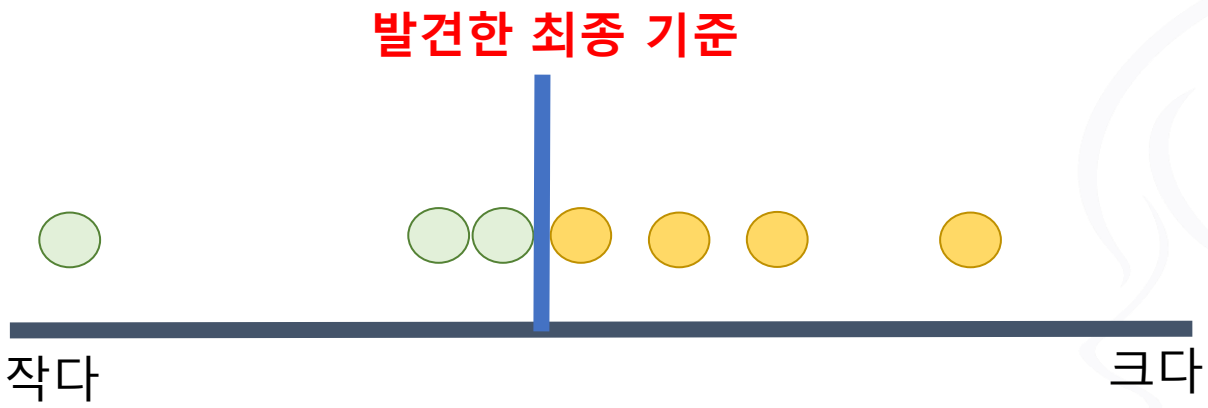

잘 익은 귤 분류하기

- 사람이 찾은 기준과 직접 하드 코딩한 프로그램(알고리즘) → ①
- AI 머신이 찾은 기준과 기준을 찾을 때 사용한 알고리즘 → ②
- ②의 경우가 딥러닝을 적용한 알고리즘의 개념임
- 서로 다른 방식을 사용하여 기준을 찾았지만 ①과 ②의 목적과 사용 방향은 동일함

딥러닝 개요

신경망 모델이란?

- 신경세포의 간단하고 효과적인 처리 방식에 착안해 구현된 머신 러닝 모델의 한 종류

- 신경세포의 형태와 동작을 극도로 단순화 시킨 뉴런 모델을 다수 연결하여 네트워크를 구성

  → 다량의 뉴런(Neuron)들이 층(Layer)으로 연결되어 간단한 계산과 연결 방식을 통해 복잡한 문제를 해결하는 모델

- 뉴런의 동작 방식은 컴퓨터 프로그램의 방식에 비해 다양한 장점을 지님

신경망 모델의 아이디어 기반

- **1943년 워런 맥컬록, 월터 피트의 최초의 신경망 모델이 시초**

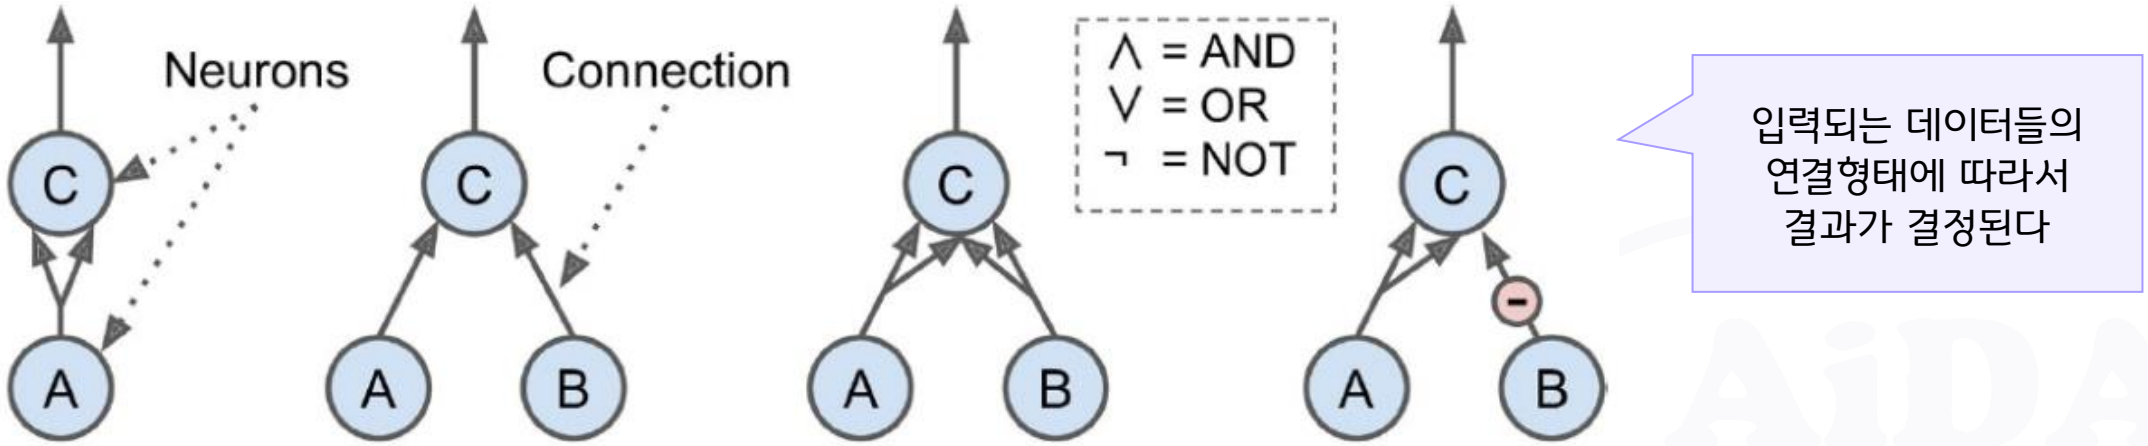

- **헵의 규칙이 신경망 모델의 동작을 정의하는 기반이 됨**
  - **시냅스의 앞과 뒤에서 동시에 신경세포가 흥분할 때, 해당 시냅스의 효율이 강화된다.**

신경세포의 구조

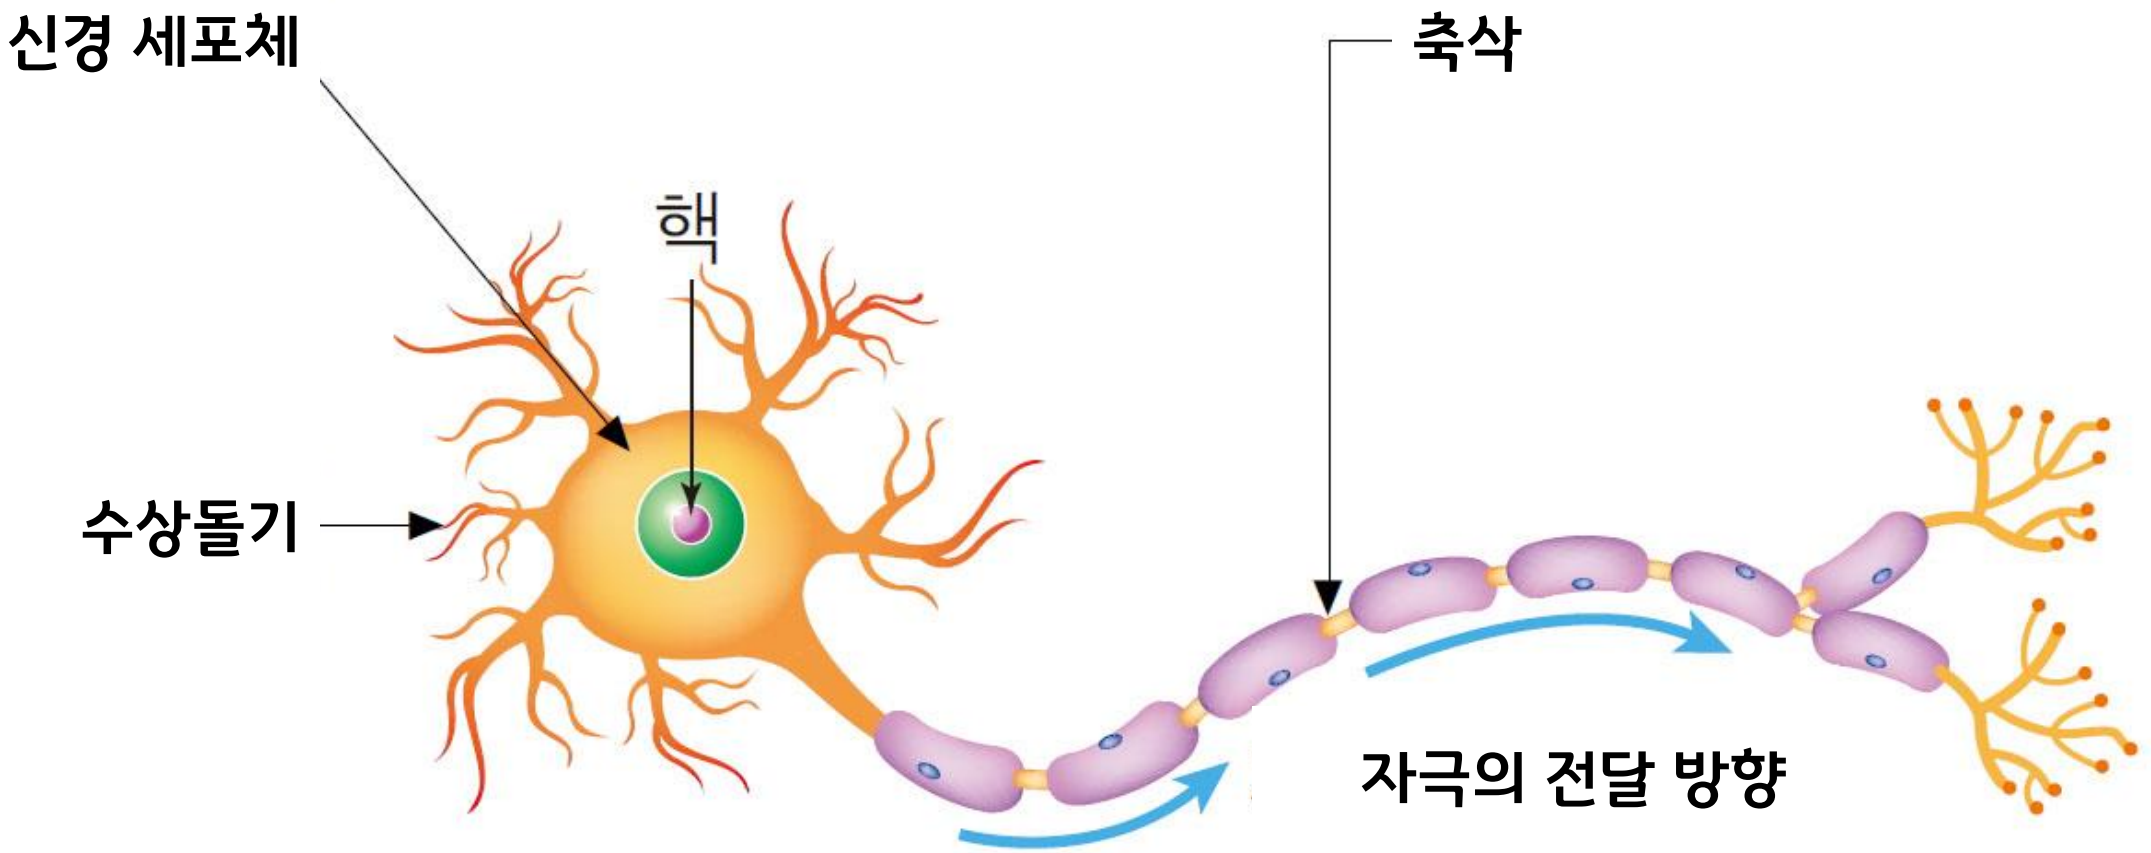

신경세포의 연결 형태

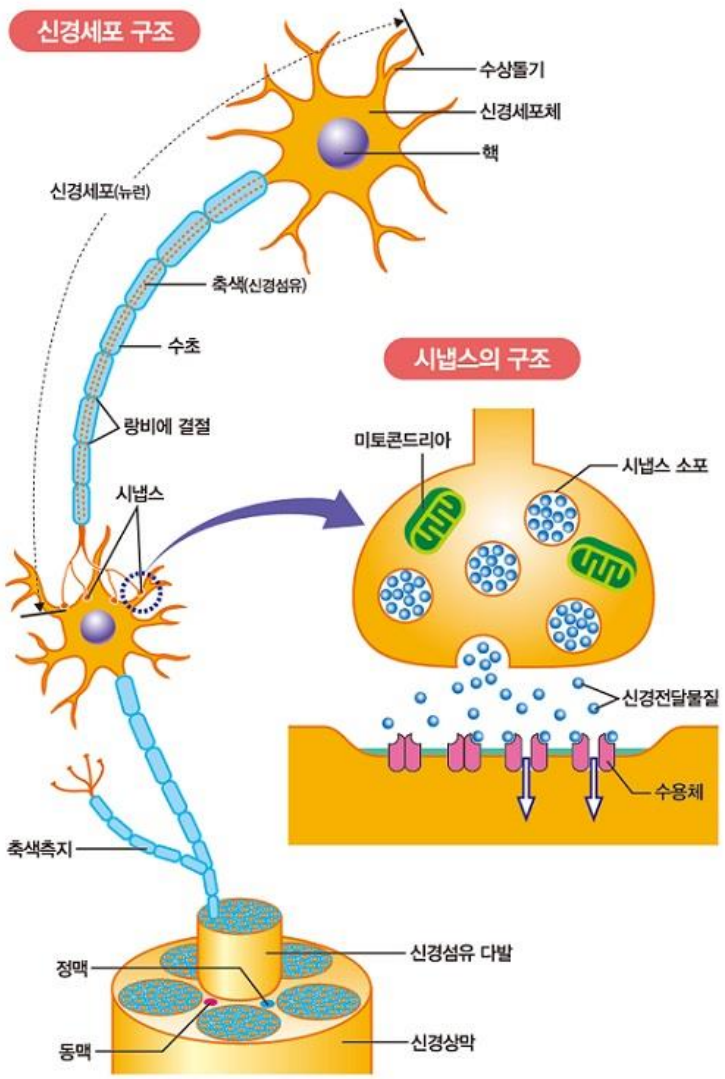

- 신호의 전달은 전기로 이루어짐
- 신경세포의 말단에는 시냅스가 존재
- 시냅스 사이의 신호 전달은 신경전달물질이라는 화학 물질을 통해전달됨
- 신경전달물질
  - 세로토닌
  - 도파민
  - 엔돌핀
  - 아드레날린 등..

신경세포의 동작

- 신경세포의 신호 처리 과정
  - 신경체계를 구성하는 수많은 신경세포들
  - 다양한 감각기관을 통하여 (전기)신호를 발생, 전달
  - 각 신경세포는 수많은 시냅스를 통해 신호를 전달 받음
  - 전달 받은 신호는 대체로 무시하지만.. 동시에 전달된 신호의 합이 임계값을 넘으면 활성화 (발산, 흥분한다 라고 표현함)
  - 활성화 된 신경세포는 활성화 패턴에 따라 신경전달물질 분비
  - 이웃 신경세포는 신경전달물질을 수용하면서 이온화 작용, 화학작용을 통하여 전기 신호 발생
  - 처리 단계 반복

신경세포, 신경망을 어떻게 단순화하였나?

- 퍼셉트론(Perceptron) 모델
  - 1958년, 심리학자 프랭크 로젠블랫(Frank Rosenblatt)이 개발한 신경망 모델
    - 당시의 인공지능-신경망 모델 중 가장 유명한 모델
  - 1960년, 로젠블랫과 동료들은 퍼셉트론이 유한하게 많은 훈련 주기에서 매개변수가 구현할 수 있는 모든 작업을 학습할 수 있음을 보여줌
    - 퍼셉트론 수렴 정리는 단층 신경망에 대해 입증됨
    - 당시의 신경망 연구는 상당수의 개인이 취한 뇌-기계 문제에 대한 접근 방식이 중심이었음
    - 뉴욕타임즈의 보고서와 로젠블랫의 진술에 따르면 신경망은 곧 이미지를 보고, 체스에서 인간을 이기며 번성할 수 있을 것이라고 주장함
  - 비슷한 시기에 등장한 기호처리 기반의 인공지능 연구 그룹과 자금 및 인력을 놓고 경쟁하게 됨

신경세포, 신경망을 어떻게 단순화하였나?

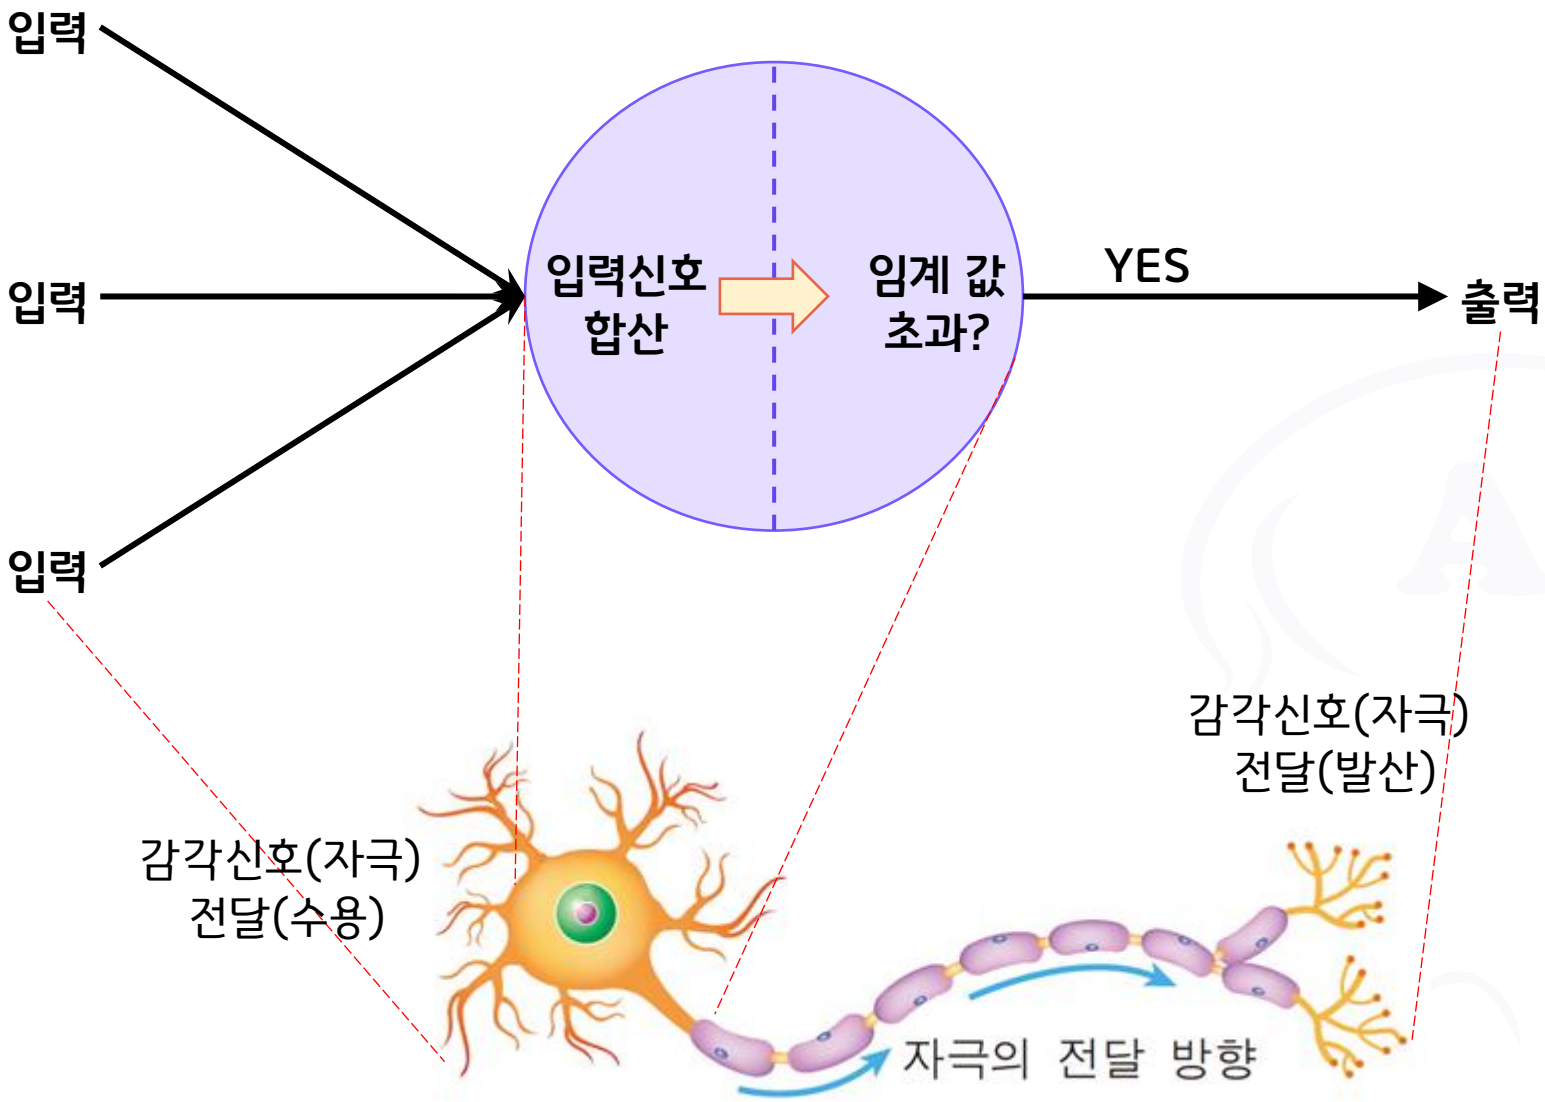

신경망의 구성

- **단층 퍼셉트론(SLP, Single Layer Perceptron)**

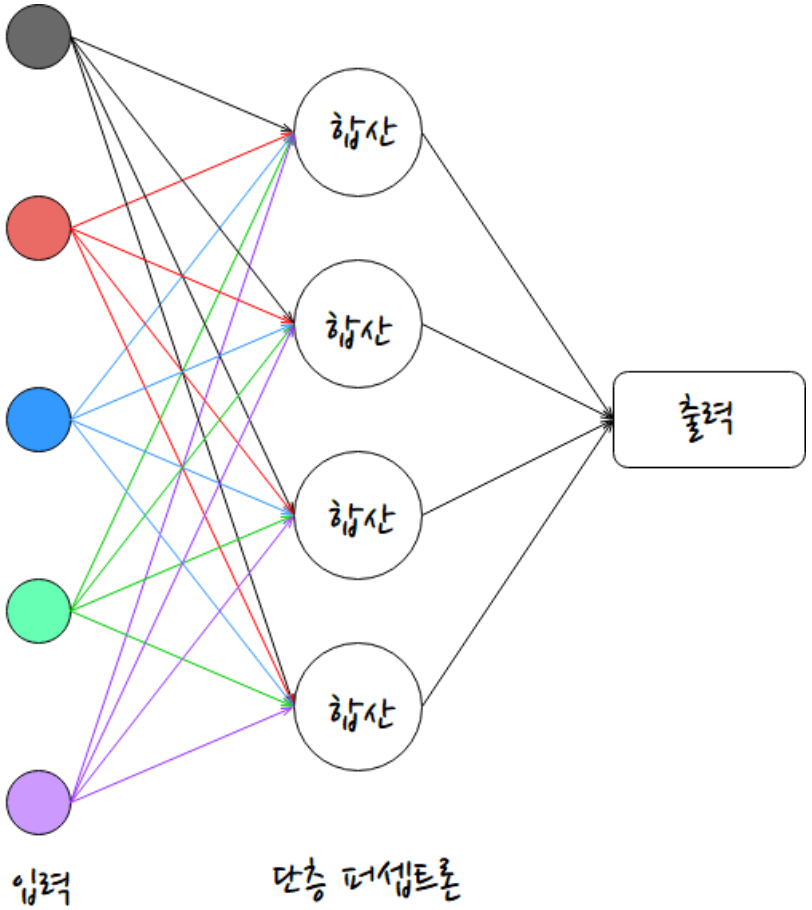

- 다수의 퍼셉트론이 하나의 층을 이루고 있는 형태
- 센서 데이터 등 다양한 데이터를 각 퍼셉트론의 입력으로 전달
- 각 퍼셉트론은 입력된 데이터를 모아서 합산
- 합산 결과가 임계 값을 넘으면 1, 넘지 않으면 0 출력
- 입력층에서 각 퍼셉트론으로 진행되는 통로에는 가중치 적용 (가중치는 모든 통로가 각각 다르게 적용될 수 있음)
- 왼쪽 그림에서 4개의 퍼셉트론이 각각 1, 0, 0, 1 이라는 결과를 낸다면, 최종 출력은 1001 이라는 2진수 값이 나오는 형태

단층 퍼셉트론의 문제점

- **단층 퍼셉트론(SLP, Single Layer Perceptron)**

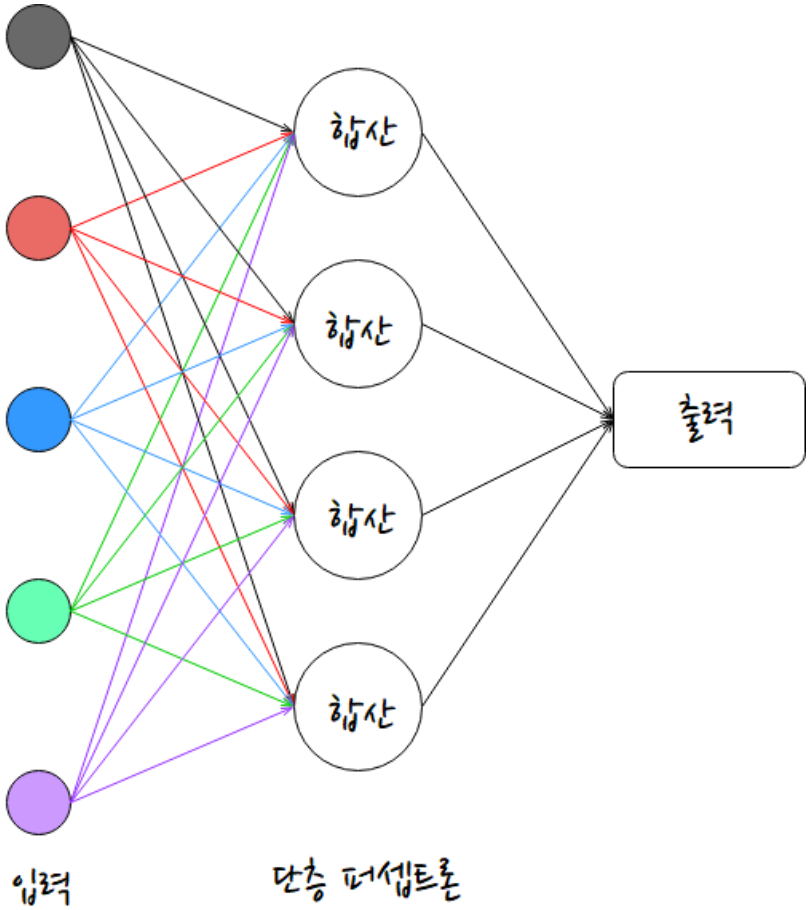

- 한 층의 변경가능한 퍼셉트론만 존재

  → 1개의 선을 그어 분리 가능한 패턴만 분류 가능

  → XOR 문제의 원인

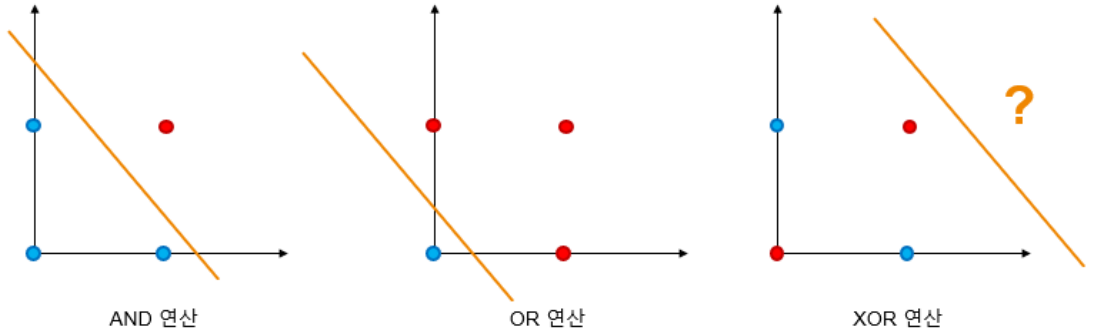

XOR문제

MIT의 마빈 민스키(Marvin Minsky), 시모어 퍼퍼트(Seymour Papert)가 1969년 발표한 논문인 'Perceptrons' 에서

신경망 모델은 XOR 연산과 같은 기본적인 논리문제를 해결할 수 없음을 증명함

→ 신경망의 겨울(암흑기)을 이끌어내는 단초가 됨

단층 퍼셉트론의 문제점

- **단층 퍼셉트론(SLP, Single Layer Perceptron)**

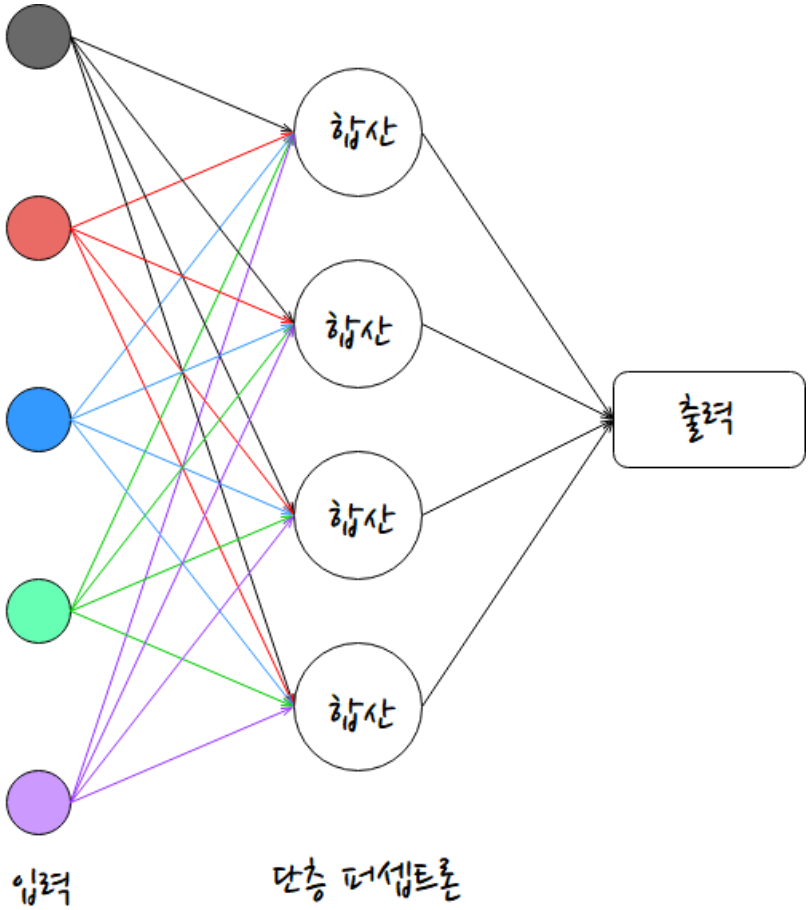

그런데 더 큰 문제는 따로 있음

- 단층 퍼셉트론의 구조를 보면…
- 가중치를 변경할 수 있는 방법이 없다 → 학습이라는 개념이 없다
- 한 번 생성된 후에는 아무런 변형이 없는 단순한 분류 알고리즘에 불과함

그 당시의 신경망 모델은 기계적으로 구성되었기 때문에
각 가중치 업데이트는 전기모터를 이용하여 직접 조정해 주었음

정확하게는 학습을 위한 개념은 연구에서도 도입되었고
Backpropagation이라는 알고리즘도 나왔지만
성공적으로 적용하지 못했음

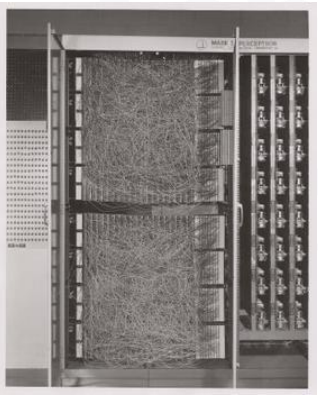

다층 퍼셉트론(Multi Layer Perceptron)

- **XOR 문제의 해결 방안 등장**

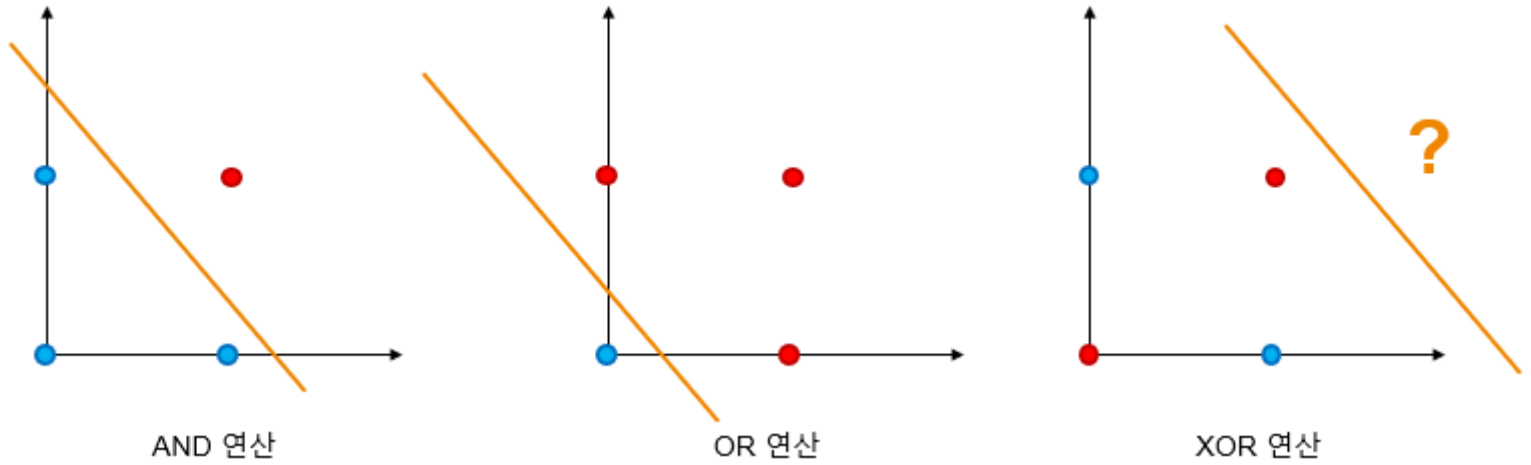

그런데 이렇게 하면?

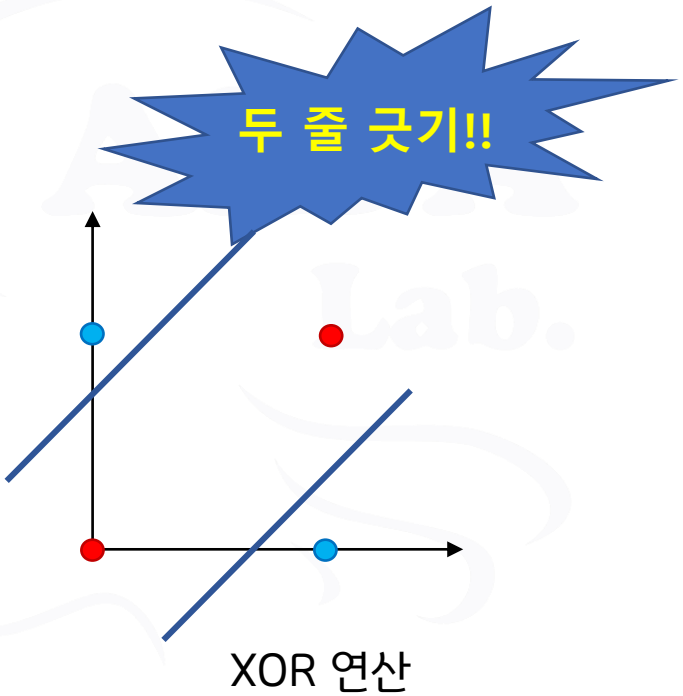

다층 퍼셉트론(Multi Layer Perceptron)

- **직선으로 데이터 분류하기**

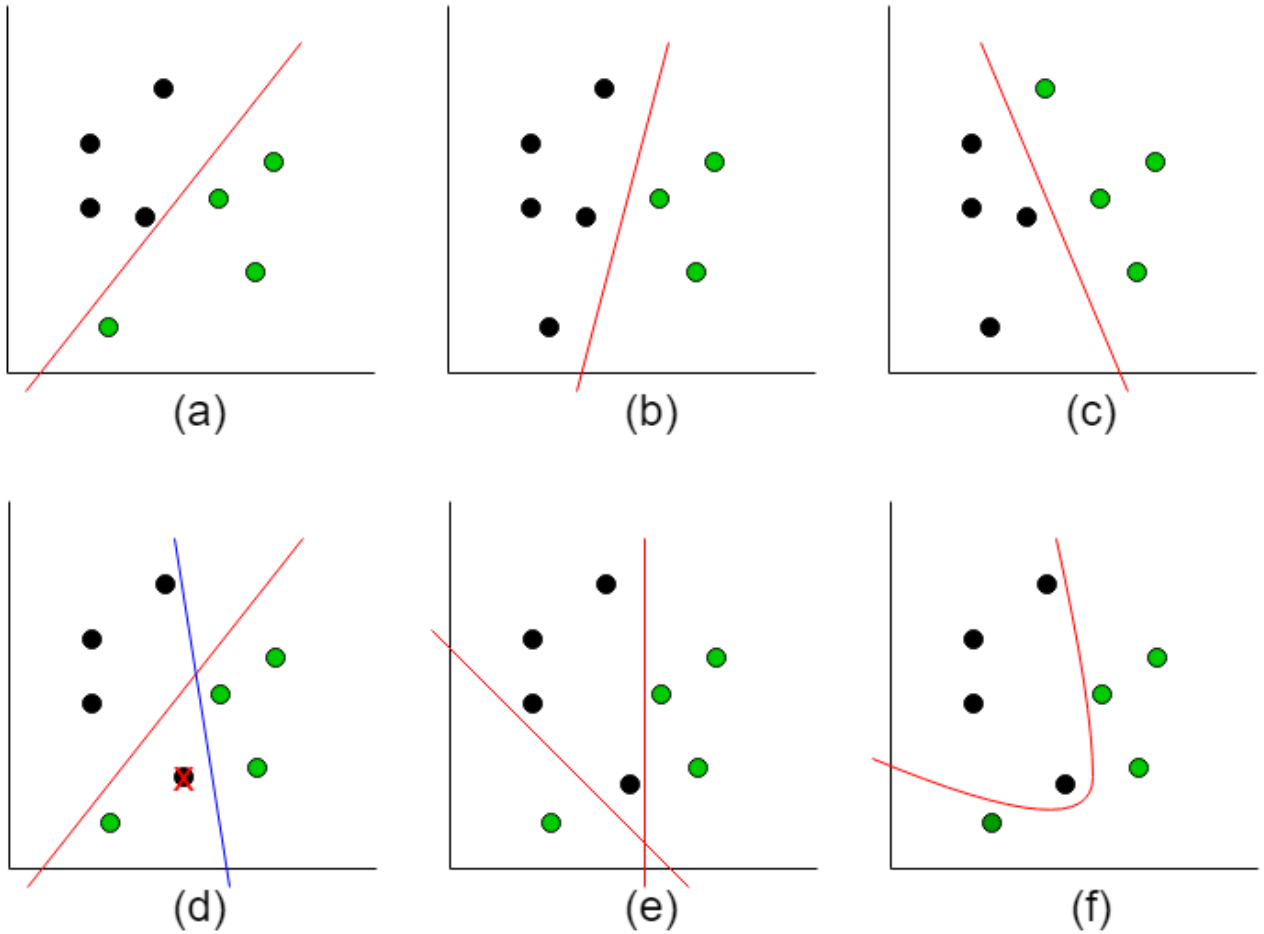

- 직선의 수를 늘림으로써 다양한 패턴의 분류가 가능해 짐

  → XOR 문제의 원인 제거 성공

  → 다층 퍼셉트론 등장

일설에 따르면 'Perceptrons'를 발표한 민스키, 퍼퍼트도 다층 퍼셉트론이 XOR 연산을 해결할 수 있음을 알고 있었다고 함

다층 퍼셉트론(Multi Layer Perceptron)

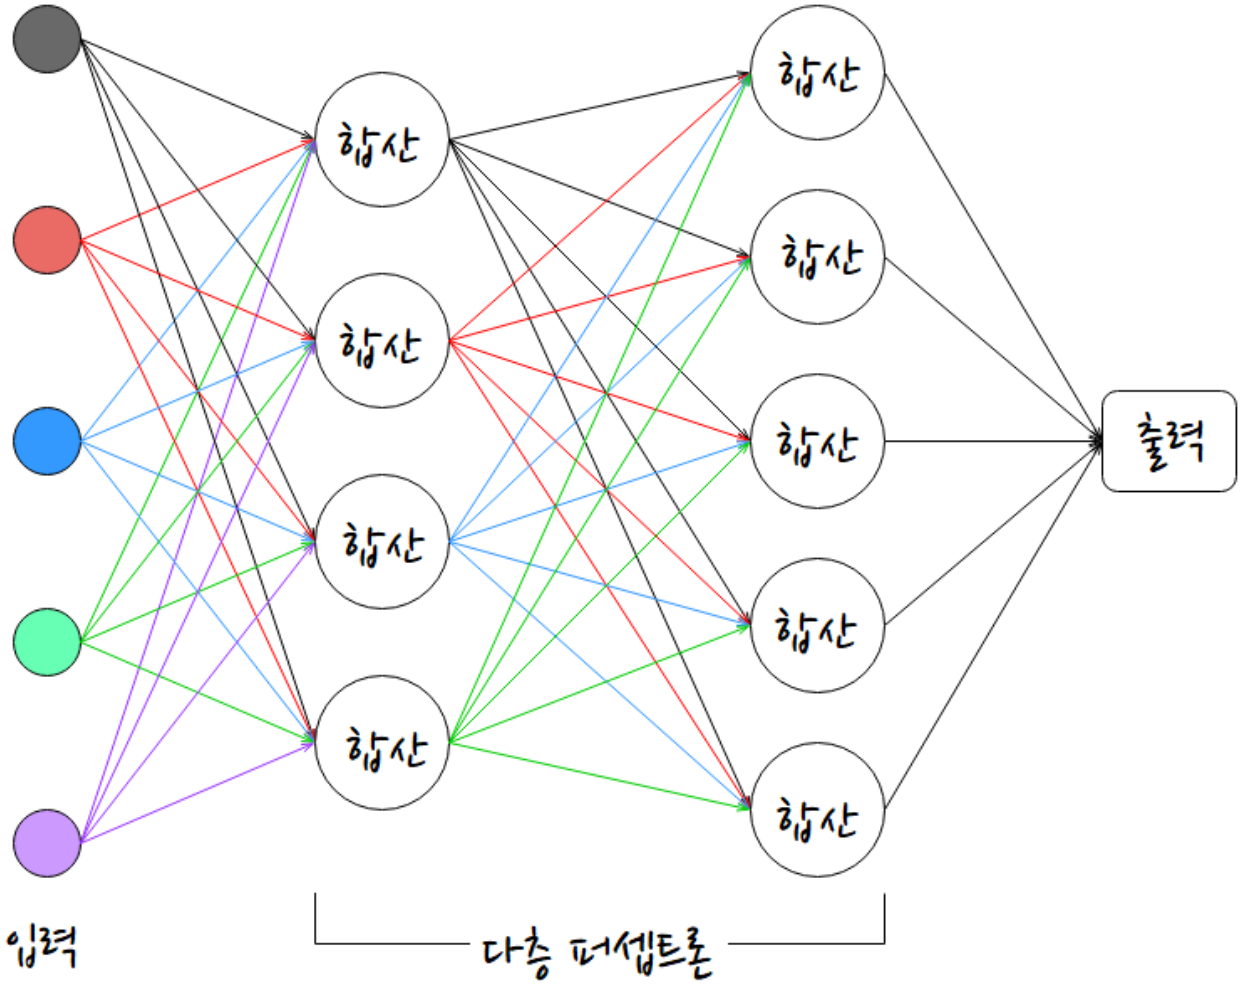

- 다수의 퍼셉트론 층이 네트워크를이루는 형태
- 처리 방식은 단층 퍼셉트론과 동일함

다층 퍼셉트론(Multi Layer Perceptron)

- 또 문제점
  - 단층 퍼셉트론과 마찬가지로 각 통로의 가중치를 변경할 방법이 없다
  - 한 번 생성되면 변경 불가능한 분류 알고리즘
  - 역시 학습의 개념이 없다 → 인공지능이 아닌 단순한 분류 알고리즘

Backpropagation
라이프니츠 연쇄규칙(Leibniz Chain Rule, 1673)을
네트워크에 효율적으로 적용한 알고리즘

1962년 프랭크 로젠블랫이 'Back-propagation Error Correctoin'이라는 용어 자체는 도입했으나
장시간동안 구현 방법을 몰랐음

- 해결책은?
  - 수행할 때마다 예전 데이터를 들고 와서 가중치를 수정해 주면 어떨까?
  - 그럼 아예 앞뒤로 왔다 갔다 반복하면서 가중치를 바꾸어 주면 어떨까?
  - Back Propagation (역전파) 알고리즘이 제안되어 왔으며

    → 1986년 Rumelhartt D. E., Hinton G. E, William R. J.의 "Learning representations by back-propagation errors" 논문에서 성공적으로 적용함

Back Propagation (역전파) 알고리즘

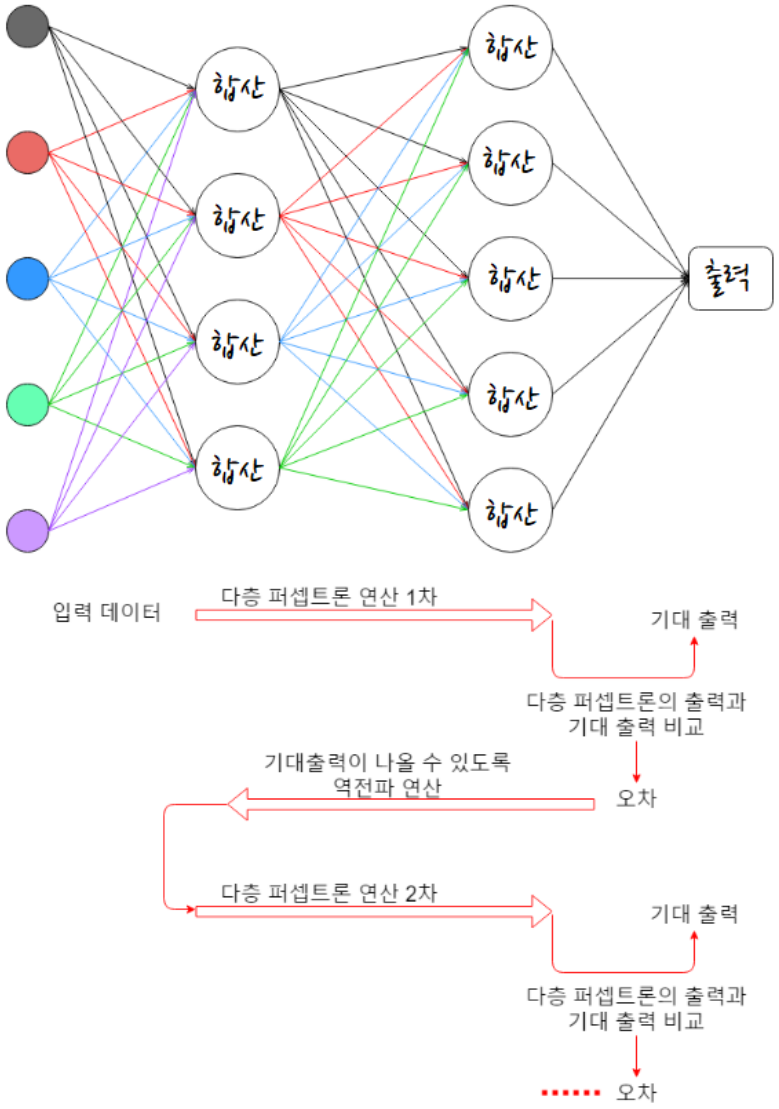

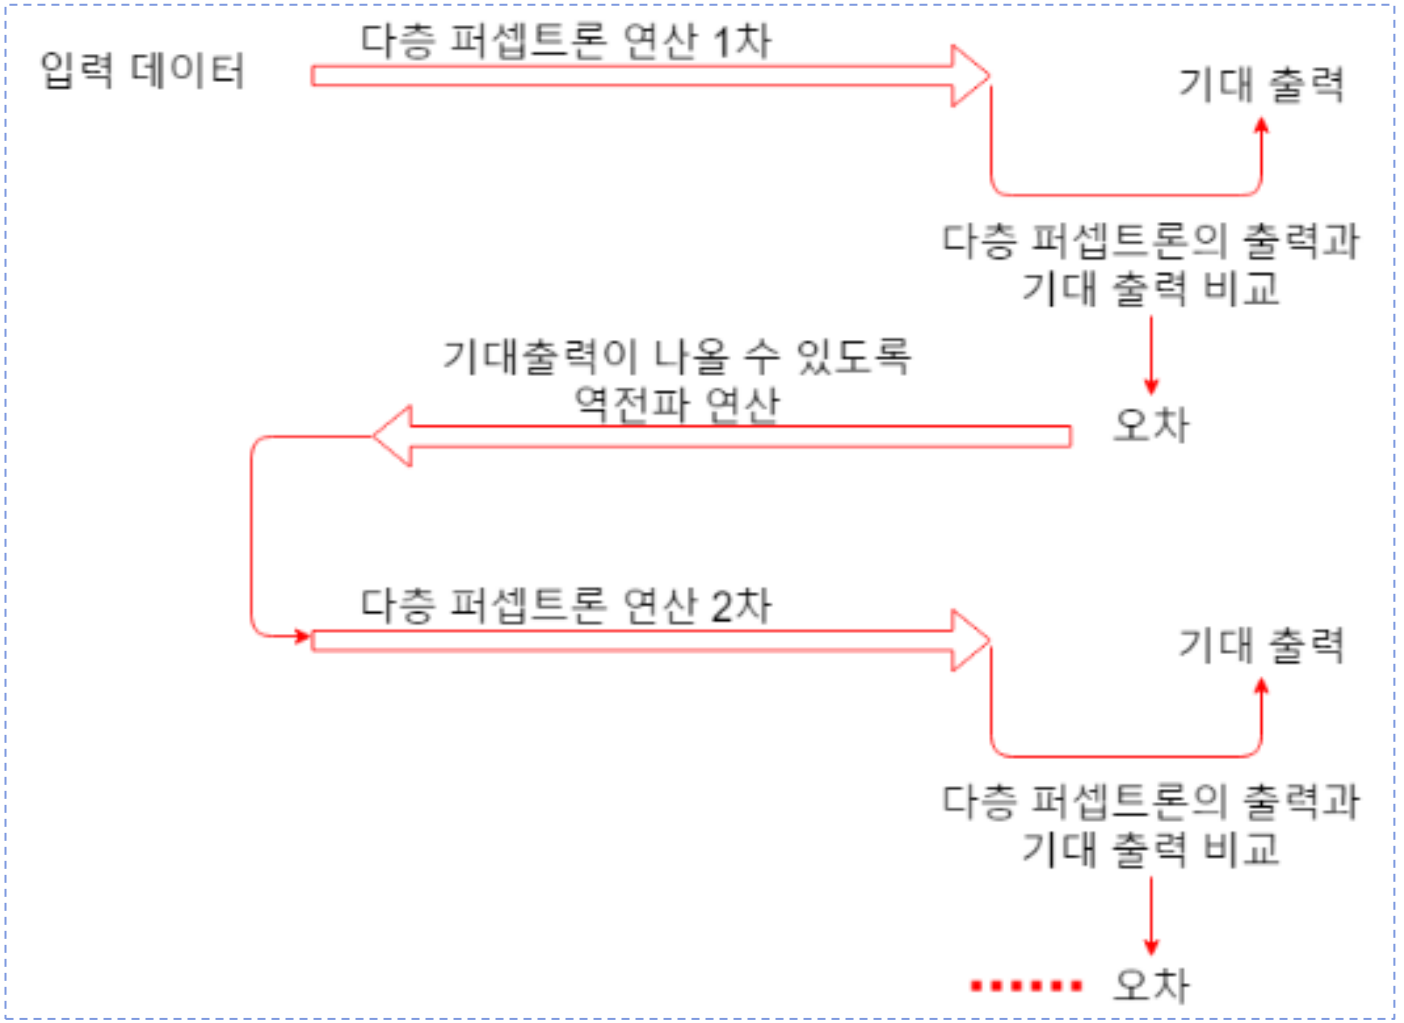

Back Propagation (역전파) 알고리즘

- 역전파 시 어떻게 가중치를 조절하는가?
  - 조절 내용: 은닉층을 거친 결과값과 기대한 결과값의 오차를 줄이는 방향으로 수정

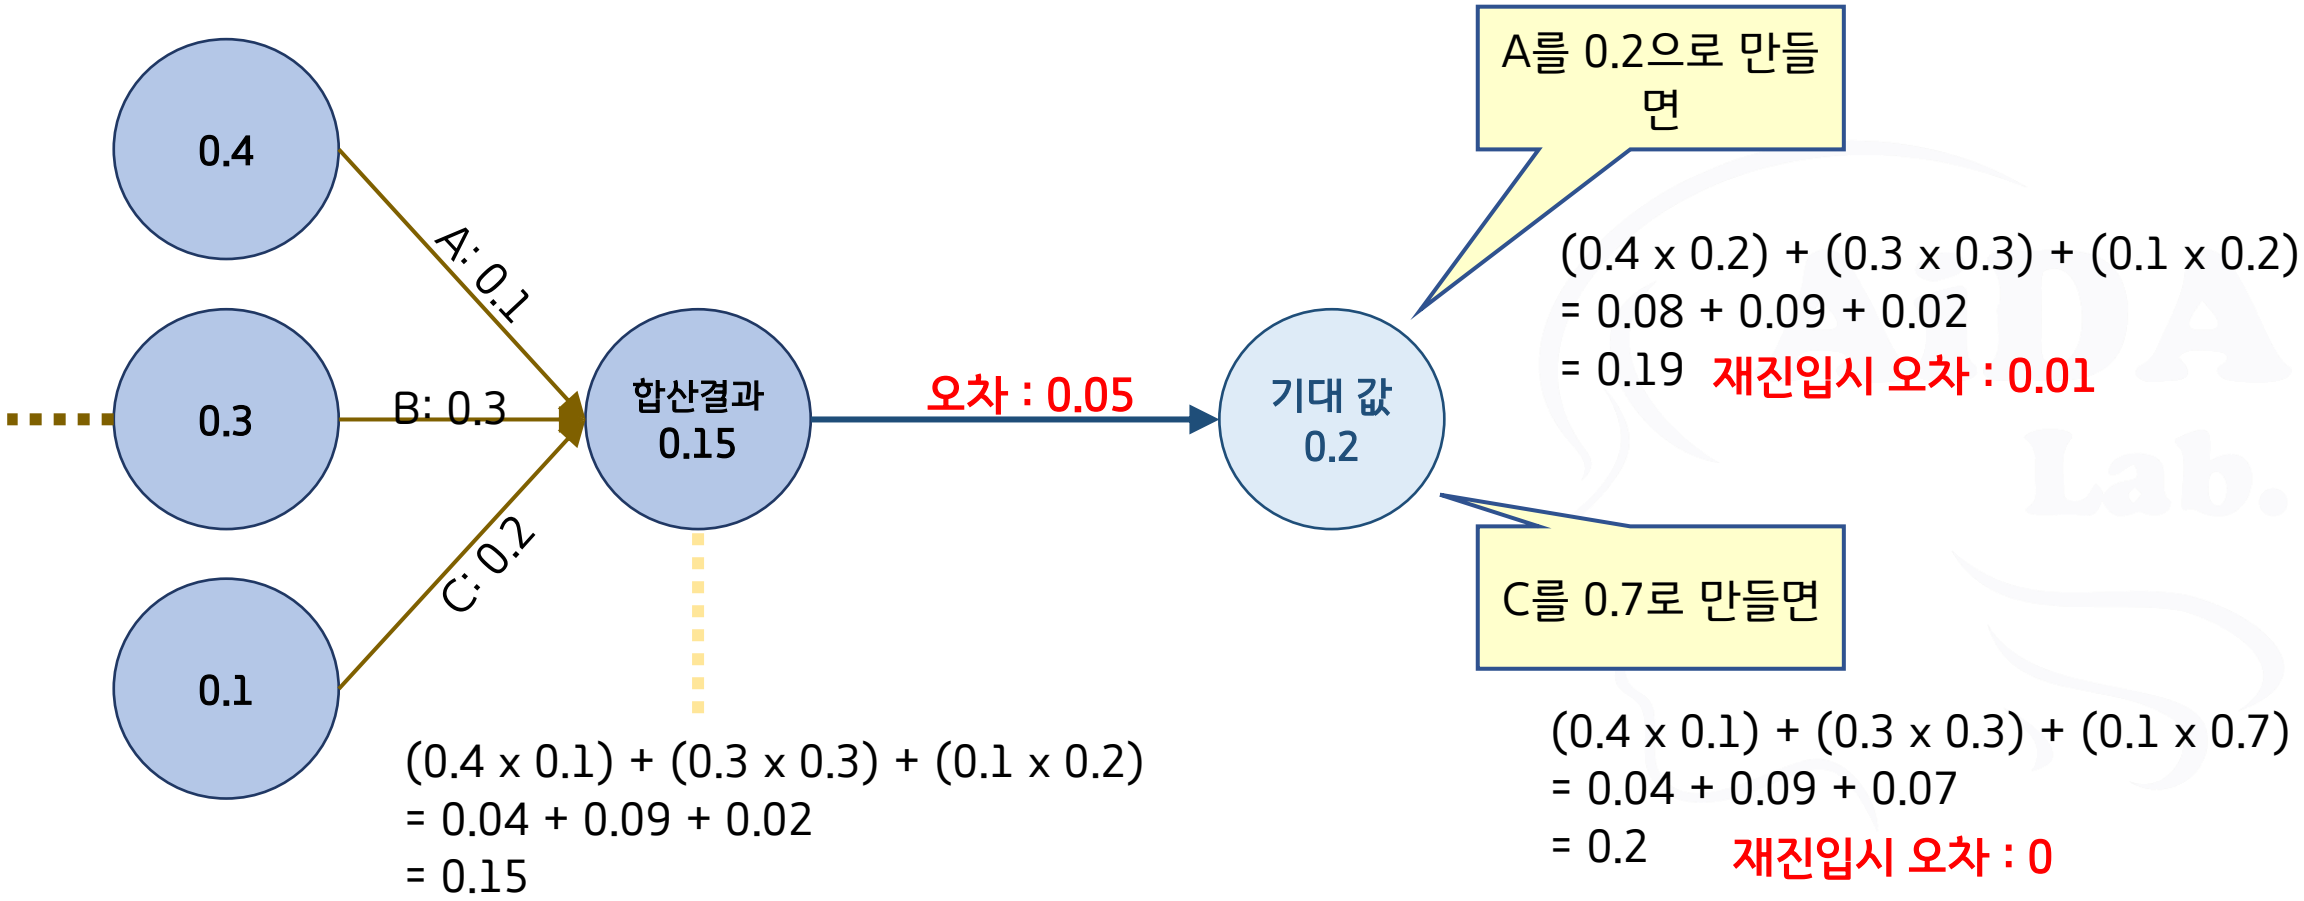

Back Propagation (역전파) 알고리즘

- 역전파 시 어떻게 가중치를 조절하는가?
  - 조절 방법

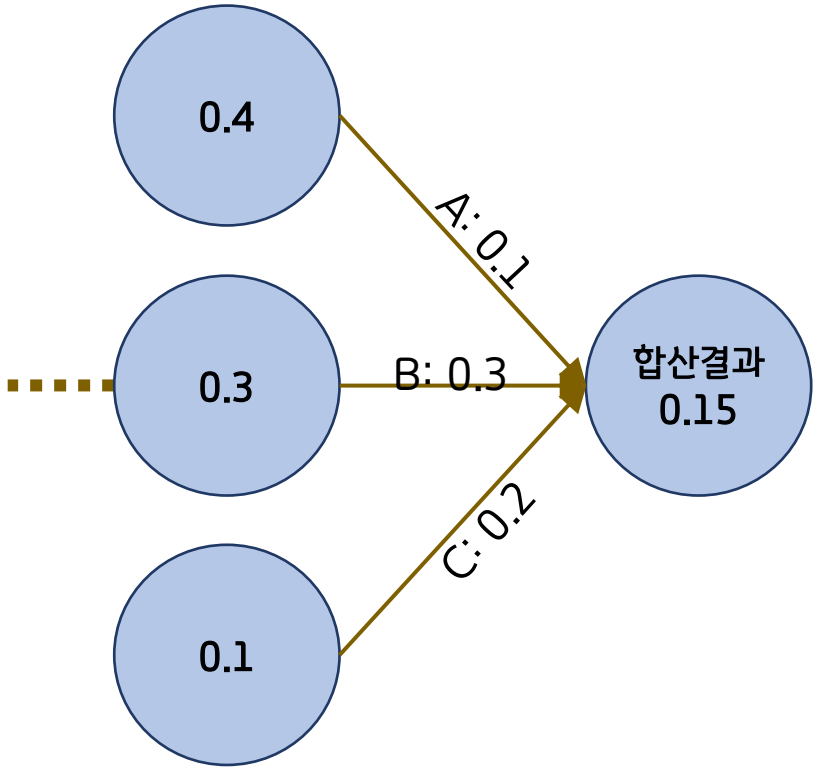

오차 값 0.05를 줄이기 위해서

- 가중치의 비율은 1 : 3 : 2
- 오차 0.05를 1 : 3 : 2 으로 나눈다
- A’ = 0.0083
- B’ = 0.025
- C’ = 0.0167
- A’ + B’ + C’ = 0.05

Back Propagation (역전파) 알고리즘

- 역전파 시 어떻게 가중치를 조절하는가?
  - 조절 방법

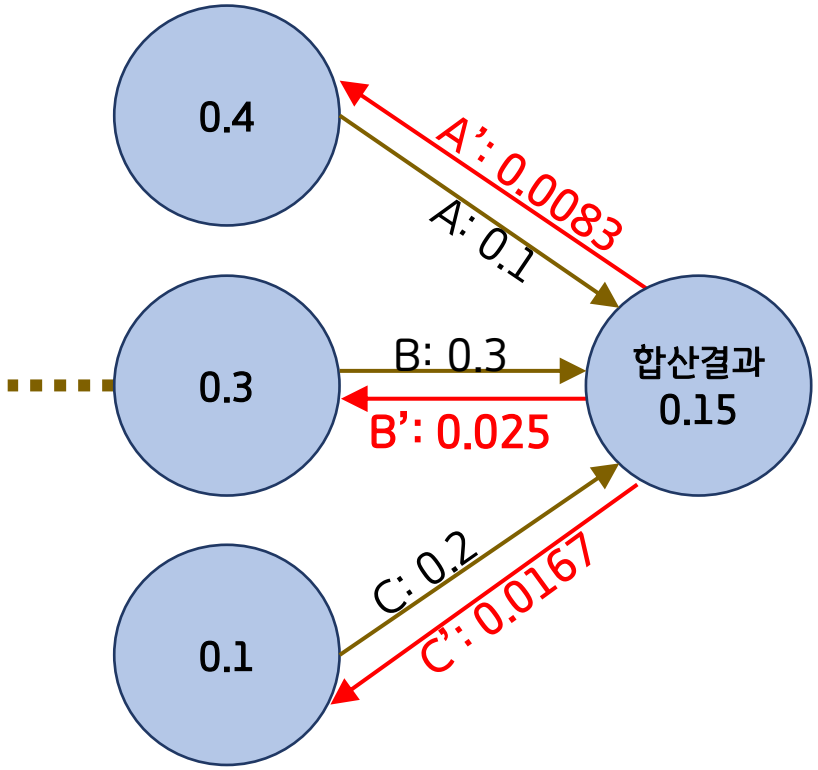

되돌려준 후 반영한다

- A = 0.1 + 0.0083 = 0.1083
- B = 0.3 + 0.025 = 0.325
- C = 0.2 + 0.0167 = 0.2167

Back Propagation (역전파) 알고리즘

- 역전파 시 어떻게 가중치를 조절하는가?
  - 조절 방법

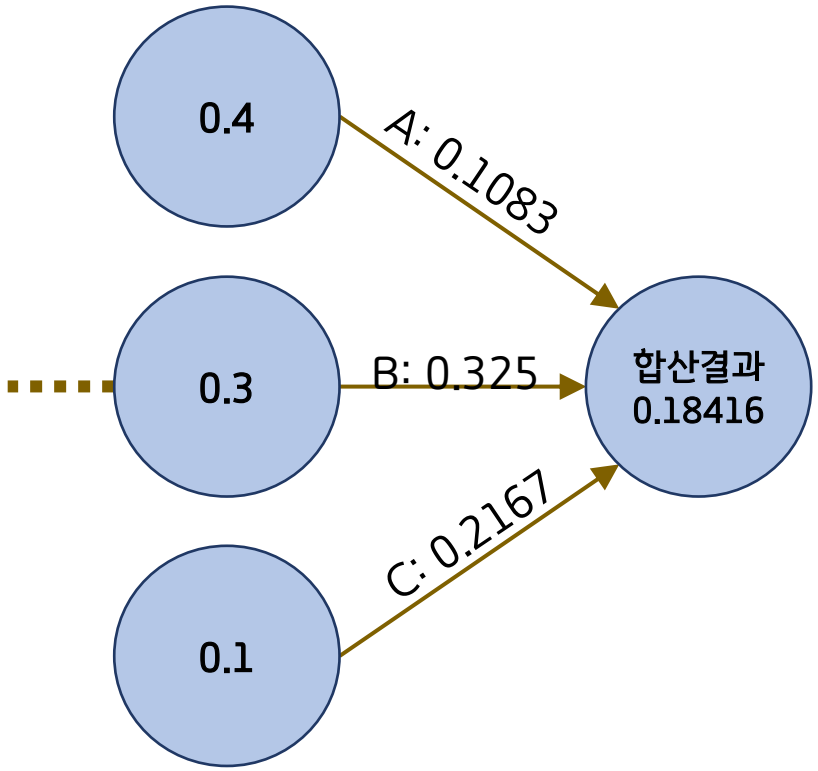

반영 후 다시 계산

- A = 0.1 + 0.0083 = 0.1083
- B = 0.3 + 0.025 = 0.325
- C = 0.2 + 0.0167 = 0.2167
- 0.4 x A + 0.3 x B + 0.1 x C

  = 0.04332 + 0.0975 + 0.04334 = 0.18416

→ 기대 값 0.2와 비교하여 → 오차 0.01584

→ 기존의 오차 0.05보다 줄어듦

Back Propagation (역전파) 알고리즘

- Back Propagation (역전파) 알고리즘을 구현한 다층 신경망에서
  - 그 층을 훨~씬 많이 만들어서
  - 수 많은 분류 작업을 수행할 수 있게 한다면?
  - 다층 신경망(Multilayer Neural Network)

    → 심층 신경망(Deep Neural Network) 으로 진화
  - 심층 신경망을 이용한 학습 모델 = 딥 러닝(Deep Learning)

가장 기본적인 딥러닝 모델: 전체 구조

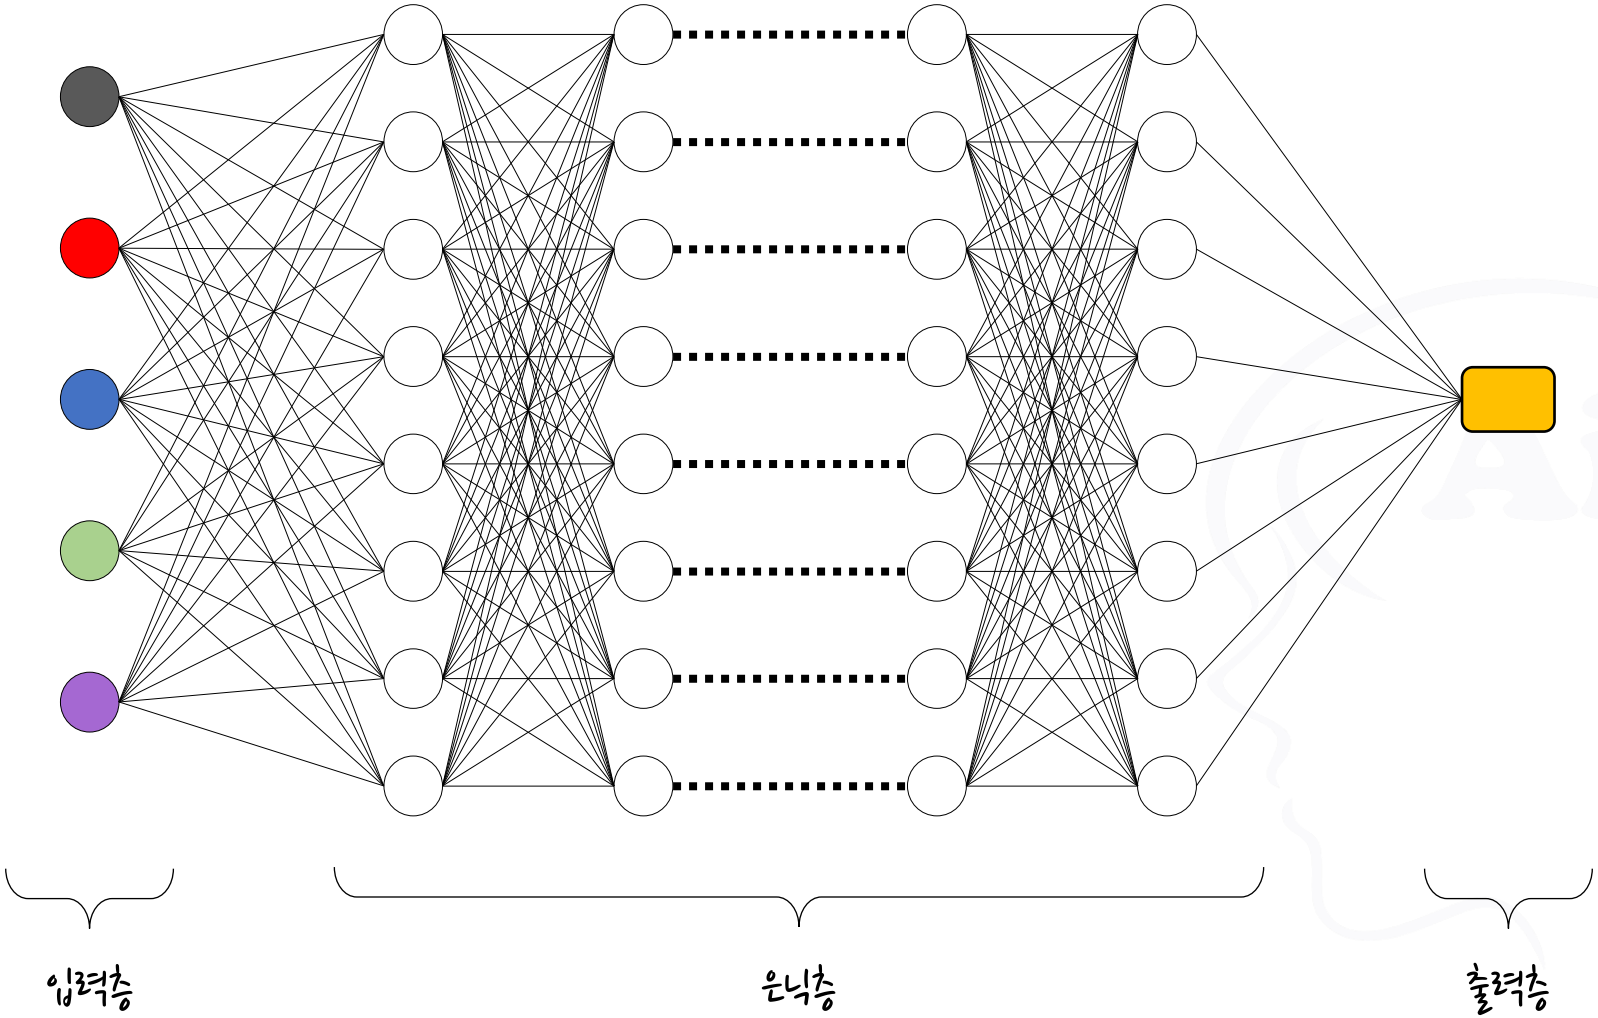

가장 기본적인 딥러닝 모델: 입력층

어떤 데이터들이 입력되는가?

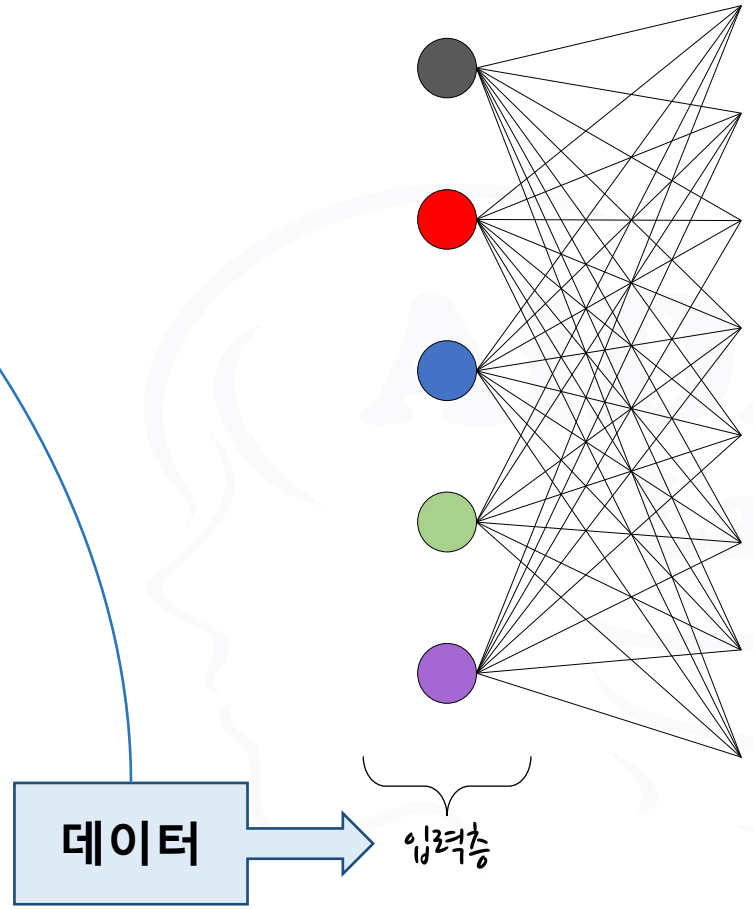

가장 기본적인 딥러닝 모델: 입력층

어떤 데이터들이 입력되는가?

- 이미지(사진) 데이터
- 동영상 데이터
- 센서 데이터
- 주식 데이터
- 기상관측 데이터
- 등...

- SNS 데이터
- Web Scraping 데이터
- 등...

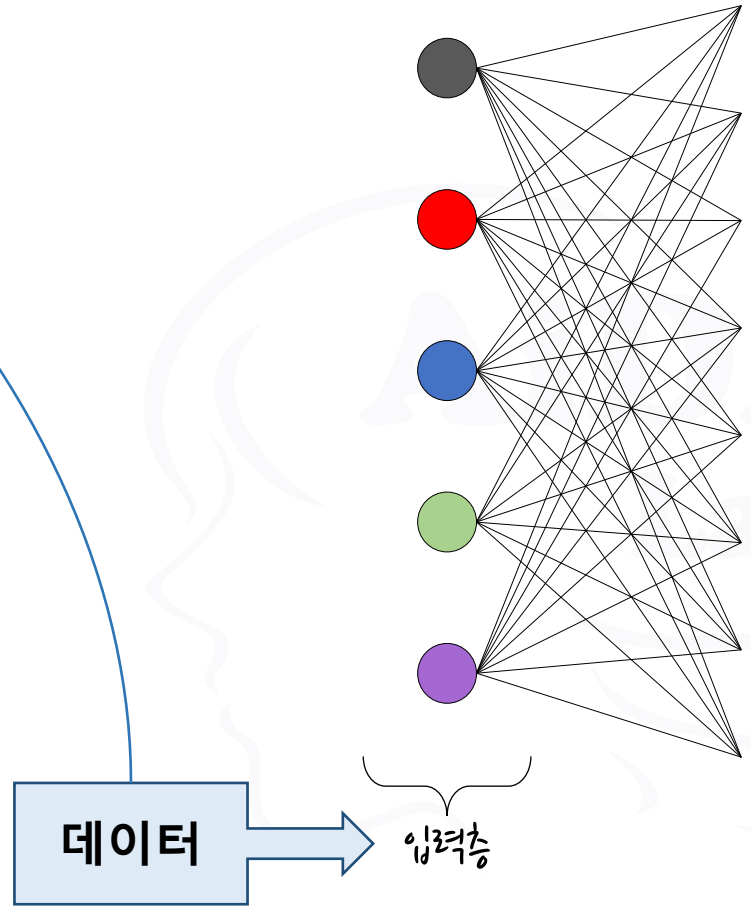

가장 기본적인 딥러닝 모델: 입력층

어떤 데이터들이 입력되는가?

- 이미지(사진) 데이터
- 동영상 데이터
- 센서 데이터
- 주식 데이터
- 기상관측 데이터
- 등…

수치 데이터

- SNS 데이터
- Web Scraping 데이터
- 등…

문자(열) 데이터 → 수치화

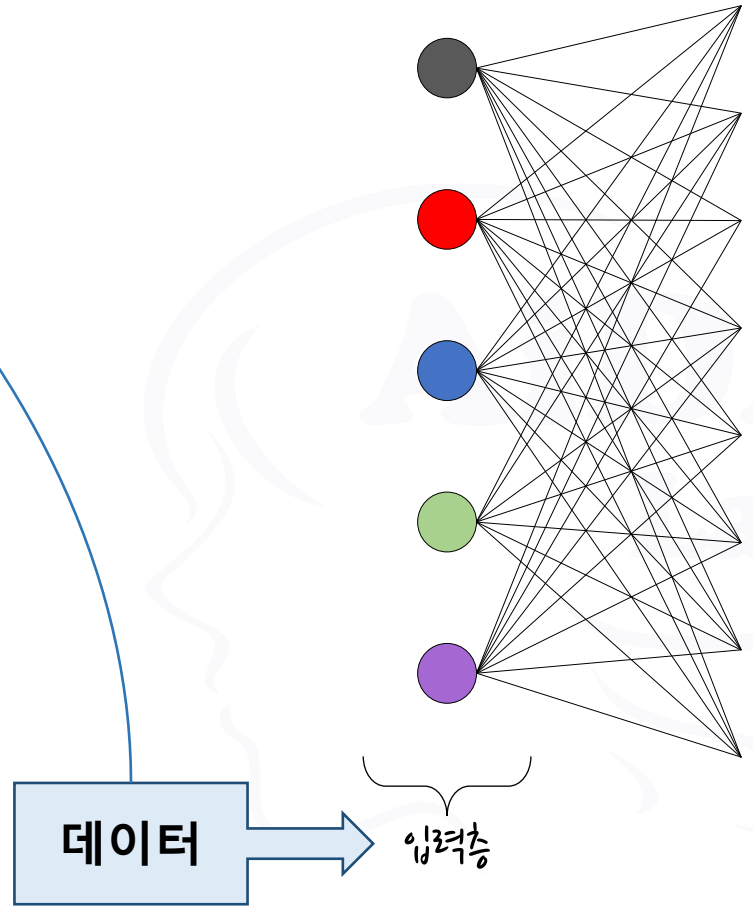

가장 기본적인 딥러닝 모델: 입력층

어떤 데이터들이 입력되는가?

- 이미지(사진) 데이터
- 동영상 데이터
- 센서 데이터
- 주식 데이터
- 기상관측 데이터
- 등…

수치 데이터

- SNS 데이터
- Web Scraping 데이터
- 등…

문자(열) 데이터 → 수치화

딥러닝에서 사용되는 데이터는

기본적으로 수치 데이터

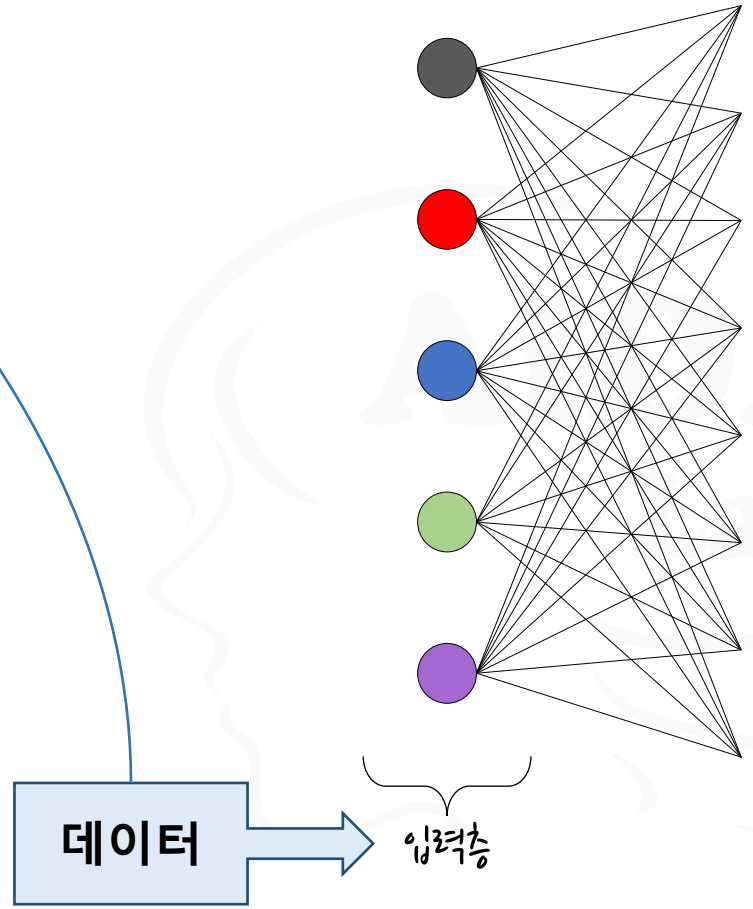

가장 기본적인 딥러닝 모델: 입력층

어떤 데이터들이 입력되는가?

- 이미지(사진) 데이터
- 동영상 데이터
- 센서 데이터
- 주식 데이터
- 기상관측 데이터
- 등…

수치 데이터

- SNS 데이터
- Web Scraping 데이터
- 등…

문자(열) 데이터 → 수치화

딥러닝에서 사용되는 데이터는

기본적으로 수치 데이터

각 노드에 하나씩 입력
→ 한 줄로 이어진 데이터

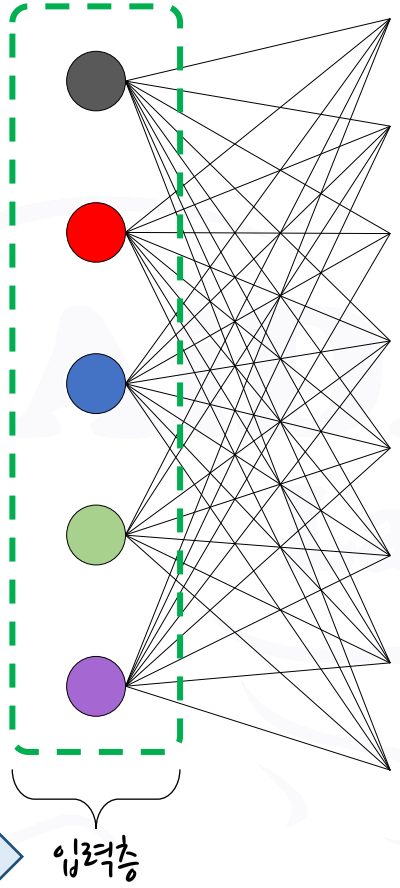

가장 기본적인 딥러닝 모델: 입력층

어떤 데이터들이 입력되는가?

- 이미지(사진) 데이터
- 동영상 데이터
- 센서 데이터
- 주식 데이터
- 기상관측 데이터
- 등…

수치 데이터

- SNS 데이터
- Web Scraping 데이터
- 등…

문자(열) 데이터 → 수치화

딥러닝에서 사용되는 데이터는

기본적으로 수치 데이터

1차원 배열로 이루어진 수치 데이터

각 노드에 하나씩 입력
→ 한 줄로 이어진 데이터

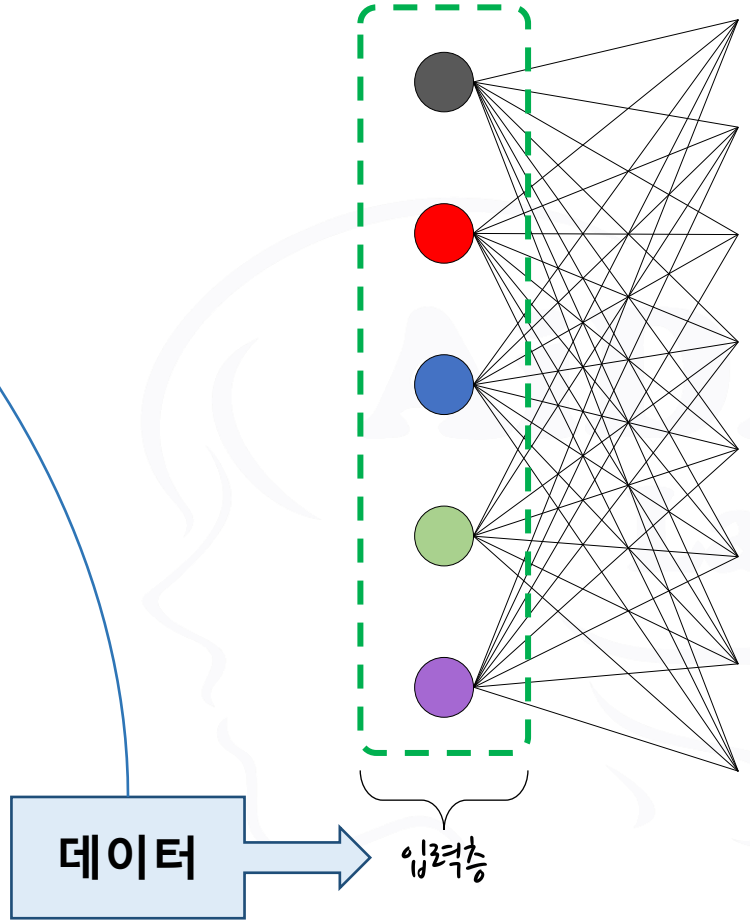

가장 기본적인 딥러닝 모델: 입력층

- 이미지 / 영상 데이터가 왜 수치 데이터인가?
  - 이미지 데이터는 색깔을 가진 수많은 점이 가로x세로 크기의 2차원 배열 속에 모인 데이터

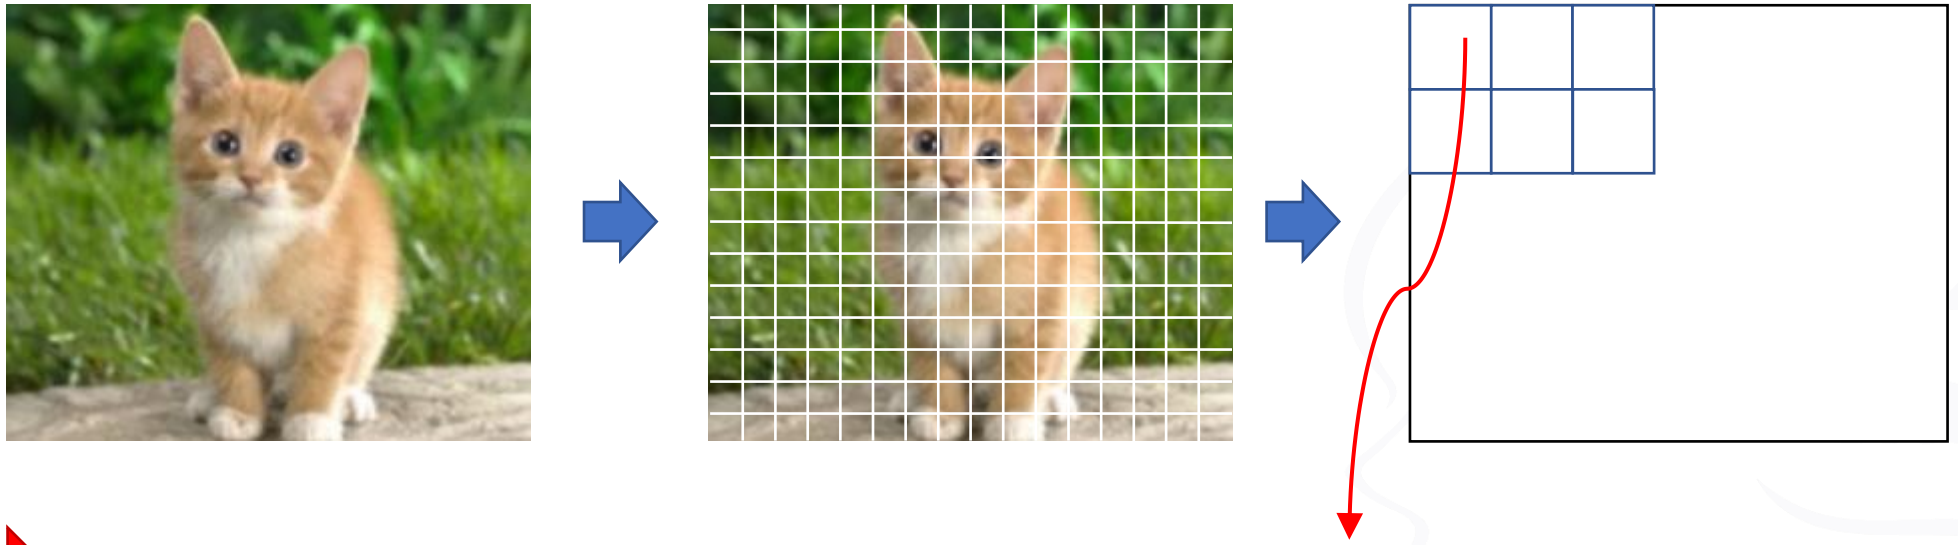

➡ 배열 데이터를 1차원으로 변환하여 입력 데이터로 사용

32832 = #008040 = #00 #80 #40 =

R G B

➡ 동영상 데이터는 다수의 이미지가 순서대로 연결된 것

가장 기본적인 딥러닝 모델: 은닉층

데이터는 어떻게 전달되는가?

- 입력층에서 입력된 데이터는
- 각 데이터가 첫 번째층의 모든 뉴런에
- 동일하게 전달됨

- 각 층의 모든 뉴런이 가진 데이터는
- 다음 층의 모든 뉴런에
- 동일하게 전달됨

실제의 신경망에서는 신경전달물질이 퍼져 나가는 범위 안의 신경세포에만 신호가 전달됨 (모델링의 한계)

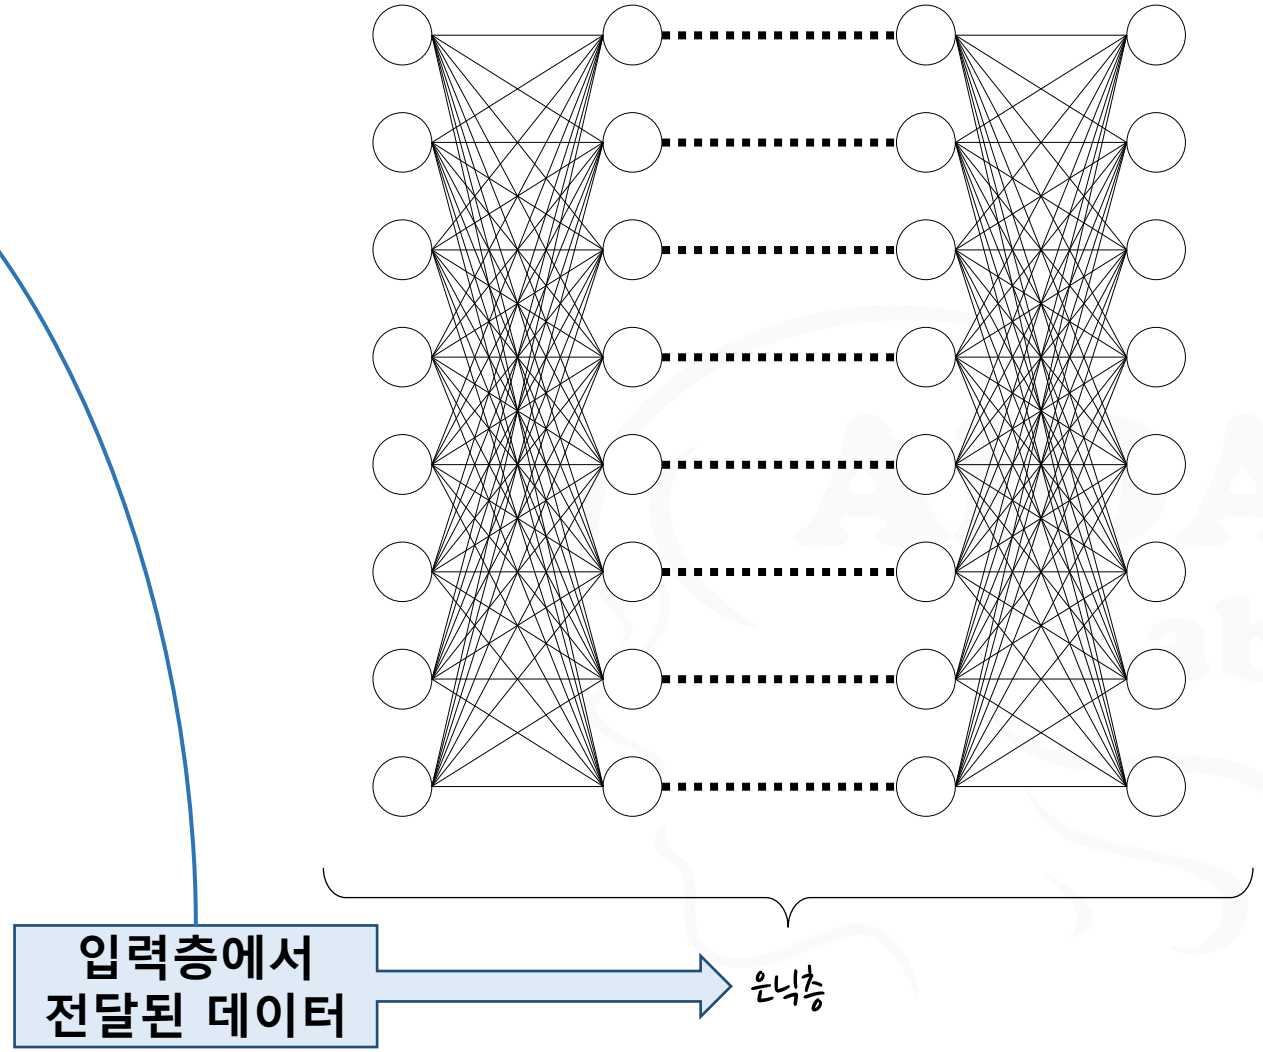

가장 기본적인 딥러닝 모델: 은닉층

각 뉴런에 전달된 데이터는 어떻게 가공되는가?

- 각 층의 뉴런은
- 입력되는 모든 데이터를
- 다 더한 후(합산)

- 합산 결과를 활성화 함수에 적용하고
- 활성화 함수(F1) 적용 결과를
- 다음 층의 뉴런으로 전달

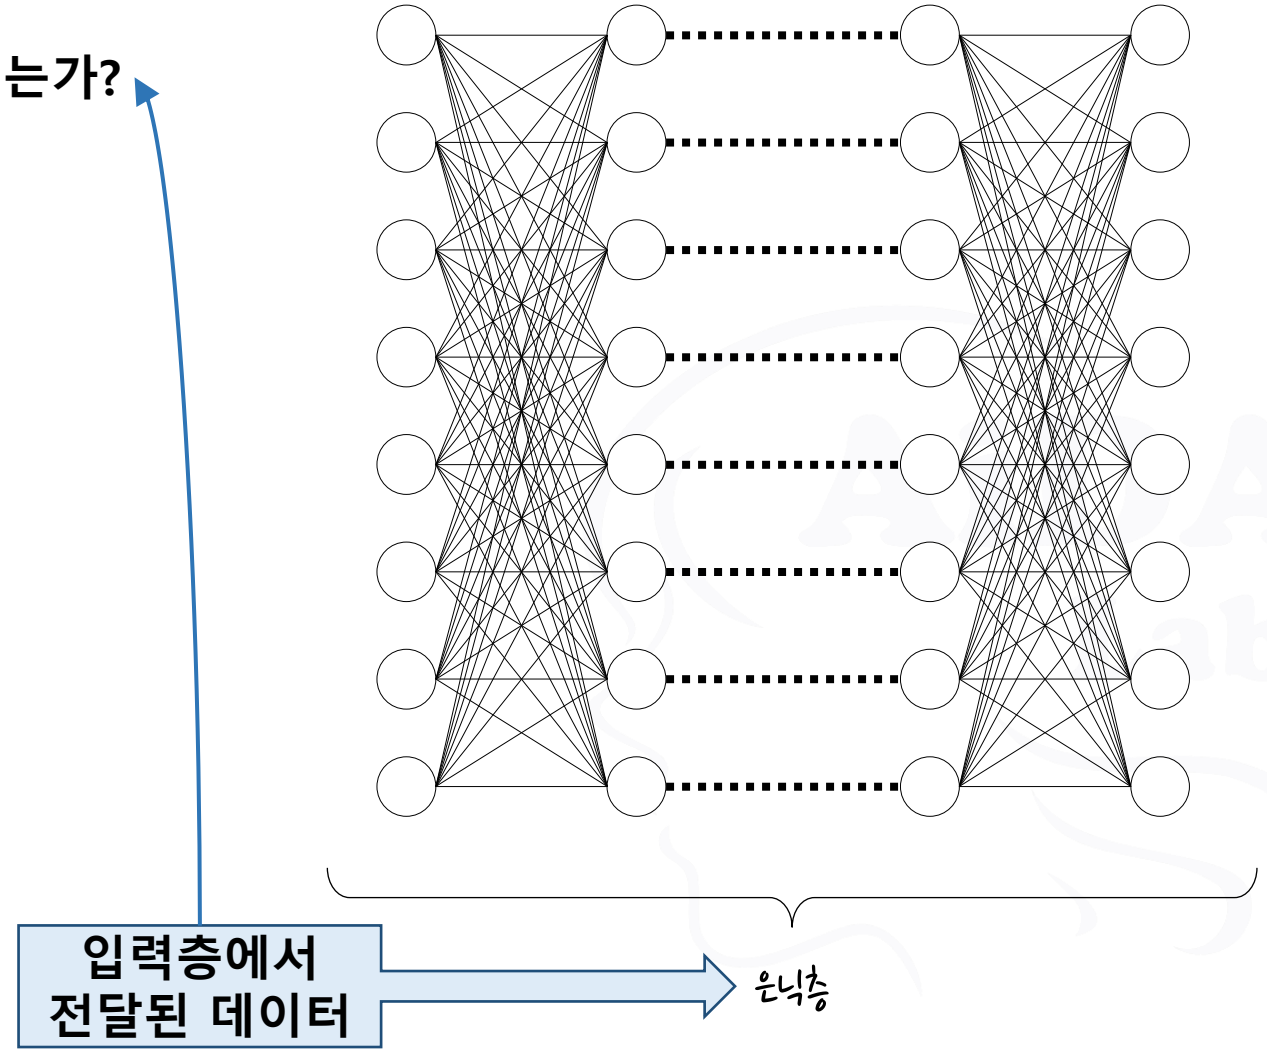

가장 기본적인 딥러닝 모델: 은닉층

은닉층은 데이터에 어떤 작업을 하는가?

- 각 층에 입력된 데이터는
- 다음 층의 뉴런으로 가는 경로에 설정된 가중치를
- 현재의 뉴런이 가진 데이터에 곱하여
- 그 결과를 다음 층의 뉴런으로 전달

- 모든 층의 데이터 이동에서
- 가중치의 곱셈과 입력 값의 합산은
- 동일하게 적용됨

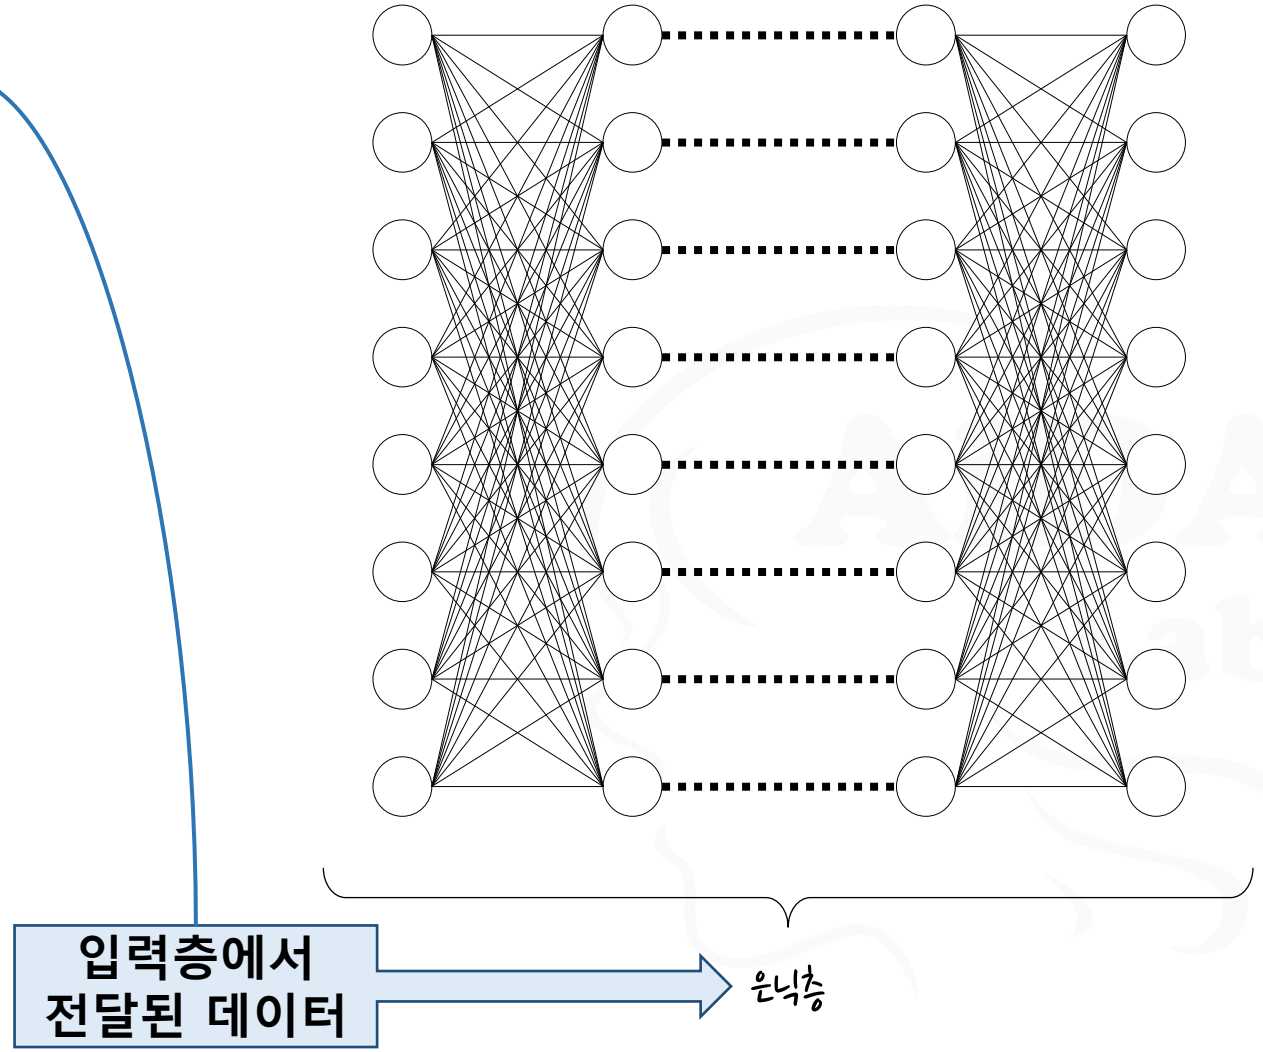

가장 기본적인 딥러닝 모델: 은닉층

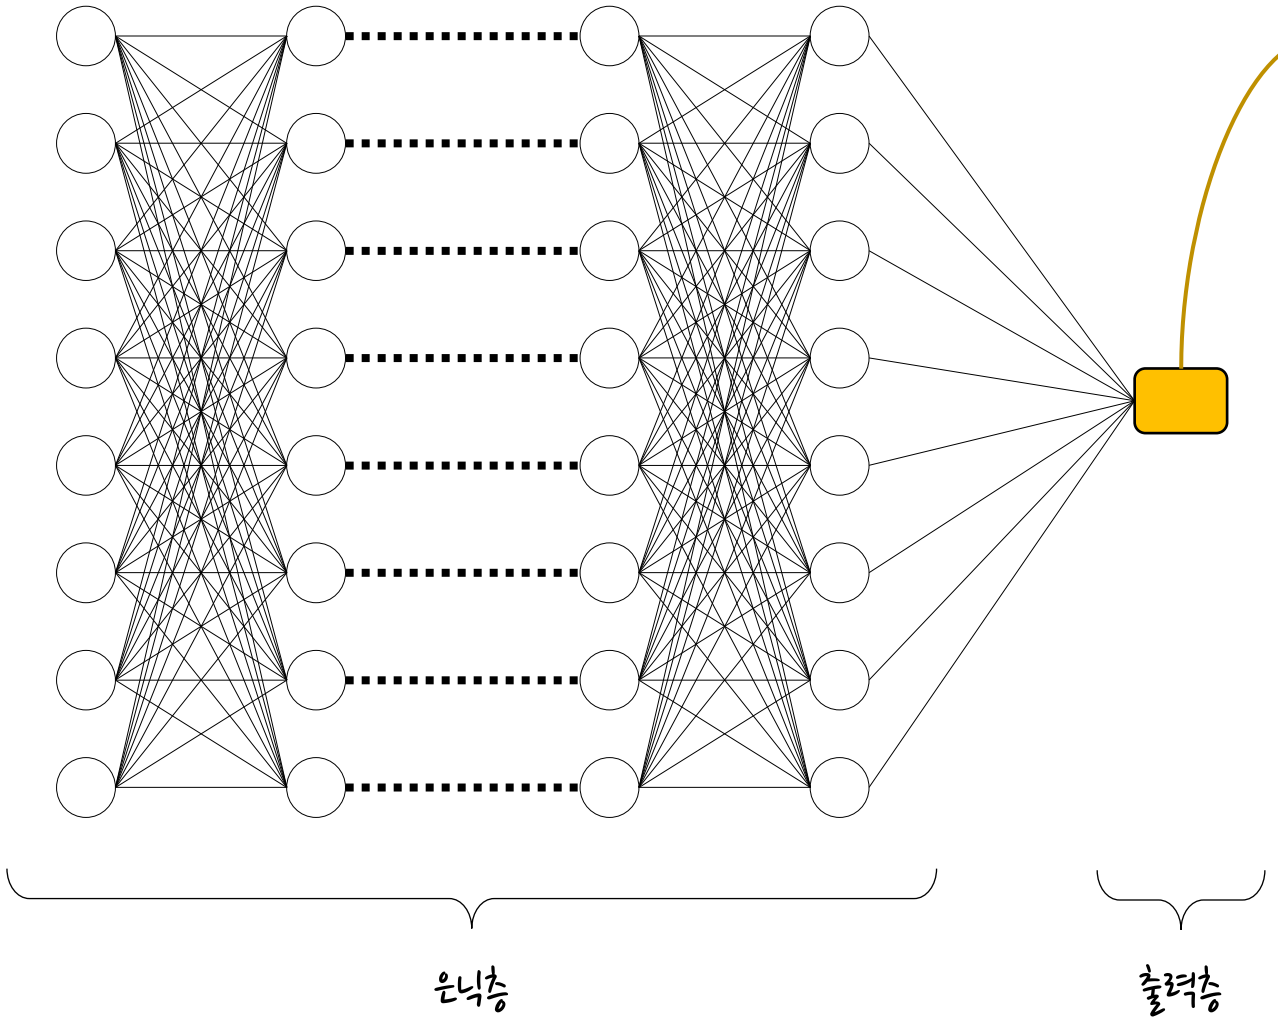

은닉층과 출력층은 함께 어떤 작업을 하는가?

- 은닉층의 마지막 층의 뉴런들은
- 자기에게 입력된 데이터를
- 합산 후
- 활성화 함수(F1)를 적용하고
- 적용 결과를
- 출력층의 출력 뉴런으로 전달

- 출력 뉴런은
- 전달된 모든 데이터를
- 순서대로 나열하여(벡터화)
- 활성화 함수(F2)를 적용하고
- 적용 결과(벡터값)를
- 결과로서 출력함

가장 기본적인 딥러닝 모델: 출력층

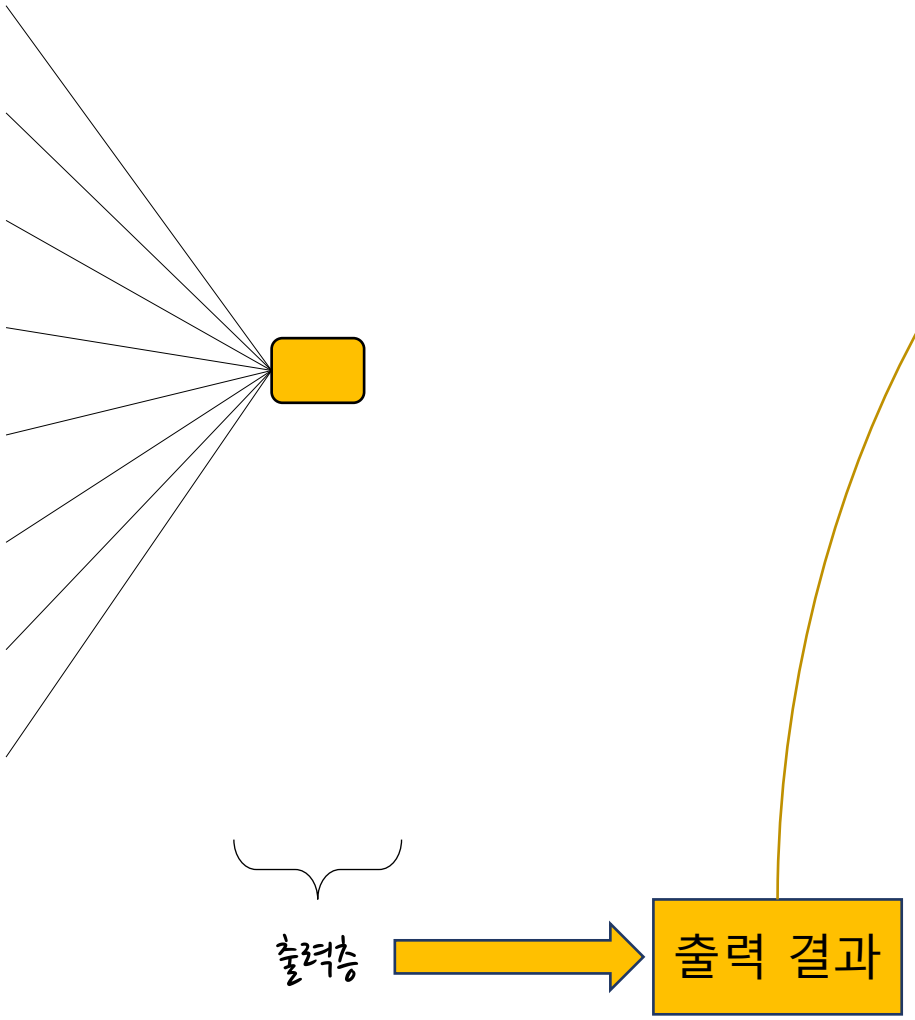

출력층에서는 어떤 결과가 나오는가?

- 출력 뉴런은
- 전달된 모든 데이터를
- 순서대로 나열하여(벡터화)
- 활성화 함수(F2)를 적용하고
- 적용 결과(벡터값)를
- 결과로서 출력함

- 출력층의 결과는
- 미리 입력된 기대 결과값과 비교하여(지도학습)
- 일치하면 → 학습 완료
- **일치하지 않으면 → 진행의 반대 방향으로 다시 전달**

딥러닝 기본 모델

은닉층에서는 데이터의 연산(가중치x데이터, 합산, 활성화)과
역전파에 의한 오류 보정(가중치 조정) 작업 수행

입력 데이터는
수치로 구성된
1차원 배열

출력 데이터로
오차 검증.
오차발생 시 역전파,
통과 시 결과 도출

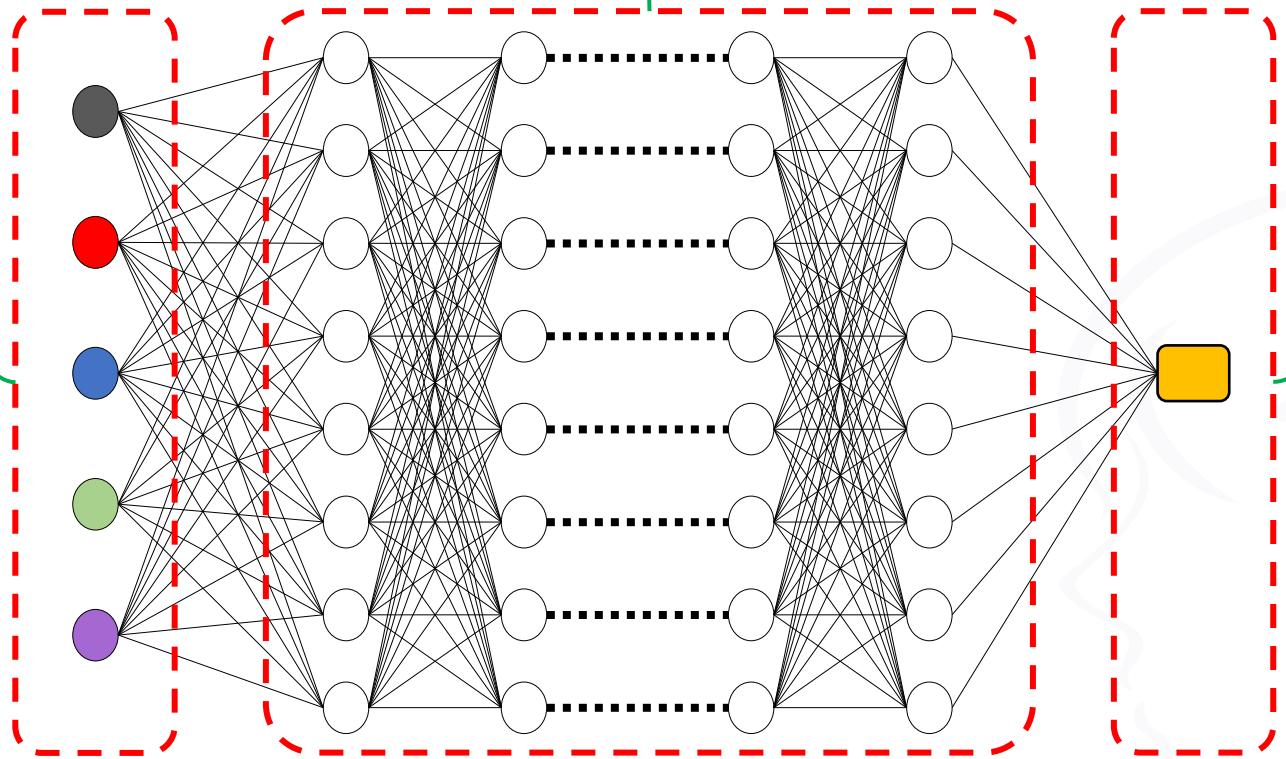

입력층 은닉층 출력층

활성화 함수

- 그럼 여기서… 각 퍼셉트론에서 임계 값을 넘으면 활성화는 어떻게 하나?
- 활성화 함수(Activation Function)
  - 신경망을 구성하는 각 퍼셉트론에서 임계 값을 넘었을 때 출력을 처리하는 함수
  - 함수의 정의
    - 입력: 이전 층의 디바이스 또는 퍼셉트론들로부터 전달되는 데이터
    - 함수의 동작: 입력 값의 합산 + 합산결과와 임계 값의 비교 + 출력 결정
      (활성화 조건)
    - 출력: 퍼셉트론 층의 연산 결과값. 다음 층의 뉴런에 대한 입력 또는 최종 층의 출력

활성화 함수

- 그런데 활성화 함수는 왜 필요한가?
  - 생물학적 / 신경과학적 필요성
    - 피부, 눈과 같은 감각기관이 어떤 자극을 받아 신호를 발생시키면

      → 그 신호는 축삭을 통해서 이동하고 → 축삭의 말단에 있는 시냅스를 거쳐 → 다음 뉴런으로 전달
    - 그런데 전달되는 모든 신호(아주 미세한 신호부터 강한 신호까지)를 모두 다음 뉴런으로 전달한다면?
      - 생활/생존 자체가 어려워지며 매우 비 효율적
      - 우리 몸에서 반응할 필요가 있는 수준까지만 신호를 전달하고 나머지의 신호는 무시한다!! → 진화의 결과
      - 이 기준을 모델에 반영한 것이 활성화 함수
  - 수학적 필요성
    - 입력 데이터는 연속, 선형 데이터이지만 출력 데이터는 이산 데이터(예측 및 분류 등)

      → 선형성을 가진 데이터를 비선형성을 가진 데이터로 변환시킬 필요가 있음

활성화 함수

- 즉, 활성화 함수란
  - 뉴런의 신호 흐름을 모델링 할 때 각각의 뉴런에 제한을 걸어 둔 것
  - 활성화 함수에서 적용한 기준에 따라 조건을 만족하는 경우에만 다음 뉴런으로 신호를 전달하기 위한 것

- 그럼 활성화 함수는 왜 그렇게 많은 형태가 존재하는가?
  - 우리는 아직 우리의 뇌와 신경들이 어떻게 동작하고 서로 어우러지는지 정확하게 알지 못함
  - 따라서 우리가 AI로 해결하고자 하는 문제에 맞게 가장 효율적이고 적절한 활성화 함수를 계속 연구, 개발하여 활용하는 것

활성화 함수

- 활성화 함수의 조건
  - 정의역(함수에 입력 가능한 값의 범위, 집합) 안에서 연속이며 무한해야 한다
  - 단조 함수여야 한다 (방향을 바꾸지 않아야 한다)
  - 비선형 함수여야 한다.
  - 계산 효율이 좋아야 한다.

이런 함수들은 부적합함

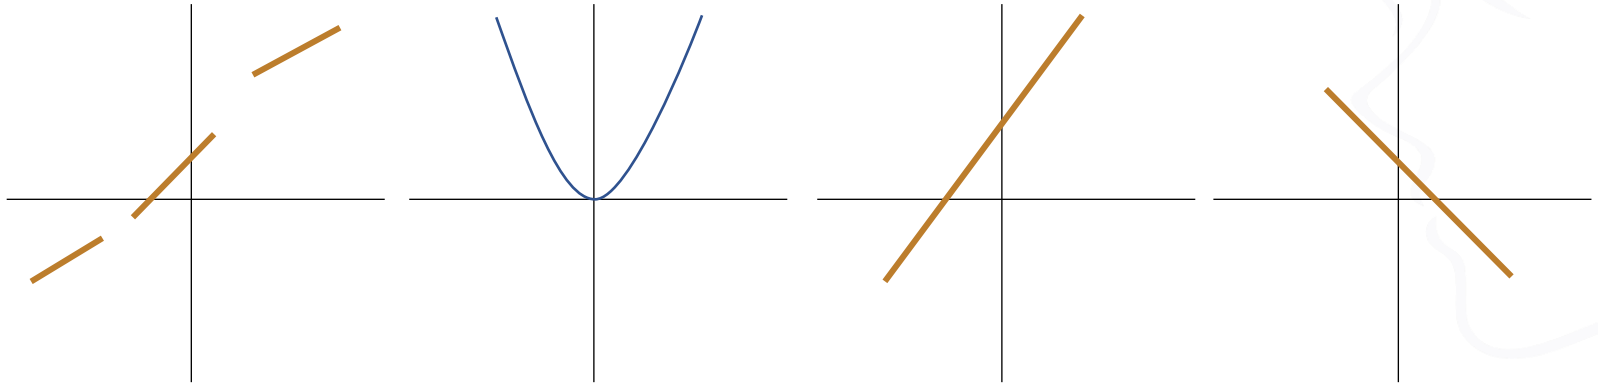

활성화 함수

- **Sigmoid**

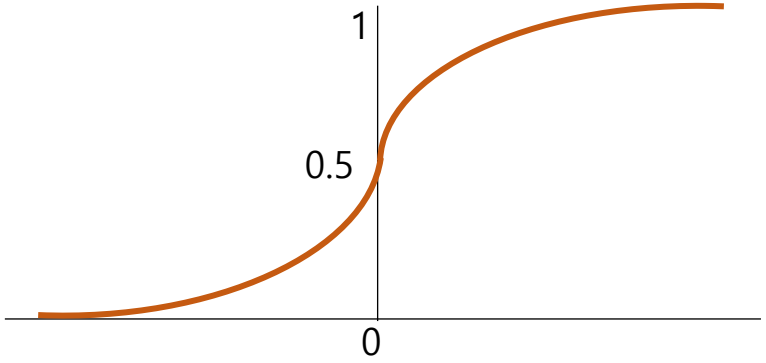

가장 많이 사용되어 왔고

가장 중요한 활성화 함수

(활성화 함수의 기본 형태)

- **tanh**

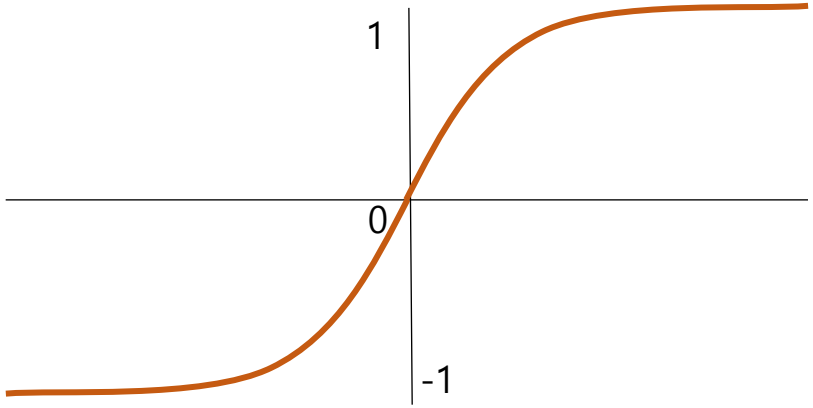

은닉층에서는 sigmoid 보다 tanh 함수가 더 좋음

음의 상관관계도 지원

활성화 함수

- **Relu (Rectified Linear Unit, 정류된 선형 유닛)**

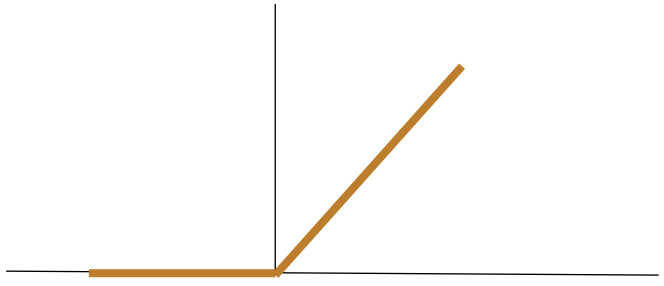

  - 데이터가 0보다 작으면 무조건 0
  - 데이터가 0보다 크면 입력값 그대로!! (주로 선형증가의 형태가 된다)

- **Softmax**

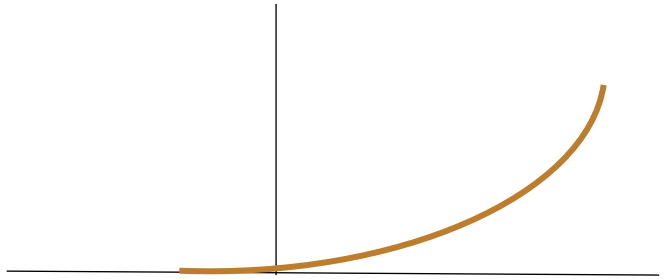

  - k개의 값이 존재할 때 각각의 값의 편차를 확대시켜 큰 값은 상대적으로 더 크게, 작은 값은 상대적으로 더 작게 만든 후, 정규화 시키는 함수
  - Softmax 함수를 거친 k개의 값의 총합은 1이 됨
  - 지수증가를 기반으로 하는 함수
  - 출력계층에서 주로 사용됨

활성화 함수

- 표준 출력 계층 활성화 함수
  - 신경망의 목적에 따라 최선의 선택이 달라진다
    - 일반 데이터의 값 예측 → 활성화 함수 미적용
    - 서로 무관한 항목에 대한 예/아니오 확률 예측 → sigmoid
    - 여러 가능성 중 하나의 확률 예측 → softmax

오차의 측정

- 출력층에서는 왜 오차를 측정하는가?
  - 신경망의 목적은 정확한 예측 결과를 얻는 것
    - 분류를 위한 모델은? 분류 역시 어떤 클래스가 가장 잘 일치할 것인가..를
      예측, 계산하여 그 값이 가장 큰 것을 선택하는 것이므로 동일하다고 볼 수 있음
  - 예측을 한 후에는 얼마나 잘 예측했는가 평가해야 함
    - 평가 방법으로 오차의 측정을 사용 → 가장 간단하고 쉬운 방법이므로
  - 특히 가중치의 조정은 미분과 관련이 있다는 것은
    → 오차의 값은 양수만 사용해야 한다는 의미

오차의 측정

- 오차의 값은 왜 양수만 사용하는가?
  - 미분은 거리, 넓이를 이용한 개념 → 거리 또는 넓이는 음수가 없음

- 어떻게 양수만으로 오차를 처리할 것인가?
  - 실제로 오차를 측정하면 양수, 음수 모두 나올 수 있지만 각 값을 거리의 개념으로 바꿔서 사용
  - 절대값, 제곱 등을 이용하여 양수로 변환함

손실 함수

- **손실 함수 (Loss Function)**
  - 출력 값과 정답(기대 값)의 오차를 정의하는 함수
  - 손실 함수는 데이터의 특성에 따라 변형, 새로 제안해서 사용 가능
  - 종류
    - 평균 제곱 오차 (MSE, Mean Squared Error)
      - 가장 많이 사용됨. 출력 값과 기대 값의 차이를 제곱하여 평균한 값 $$MSE = \frac{1}{n}\sum_{i=1}^{n}(\widehat{Y}_i - Y_i)^2$$
      - 큰 오차는 더욱 크게, 작은 오차는 더욱 작게 → 처리할 때에는 큰 오차에 더 집중
        (전반적인 성능 향상에 더 좋음)
    - 교차 엔트로피 오차 (Cross Entropy Error)
      - 범주형 데이터의 분류에 주로 사용 $$CEE = -\sum_{i=1}^{n} Y_i \cdot log\widehat{Y}_i$$

손실 함수

- 왜 손실함수를 사용하는가?
  - 학습의 궁극적인 목적은 높은 정확도를 끌어내는 매개변수를 찾는 것
  - 왜 “정확도”라는 지표를 놔두고 “손실함수의 값”이라는 우회적인 방법을 사용하는가?

신경망 학습에서 미분의 역할을 생각해보면

  - 신경망 학습에서는 최적의 매개변수를 탐색할 때, 손실함수의 값을 가능한 작게 만드는 매개변수의 값을 찾음
  - 이때 매개변수의 미분을 계산하고, 그 미분 값을 단서로 매개변수의 값을 서서히 갱신하는 과정을 반복함
    - 손실함수의 미분 값이 음수 → 가중치 매개변수를 양의 방향으로 변화시켜 손실함수의 값을 줄일 수 있다.
    - 손실함수의 미분 값이 양수 → 가중치 매개변수를 음의 방향으로 변화시켜 손실함수의 값을 줄일 수 있다.
    - 손실함수의 미분 값이 0 → 어느 쪽으로도 움직이지 않으므로 갱신이 멈춘다.

손실 함수

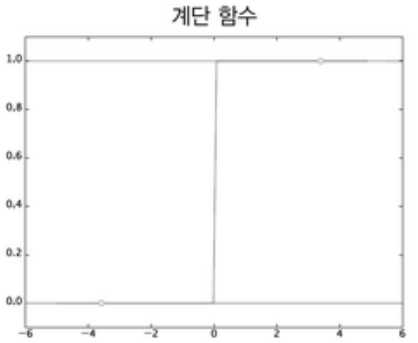

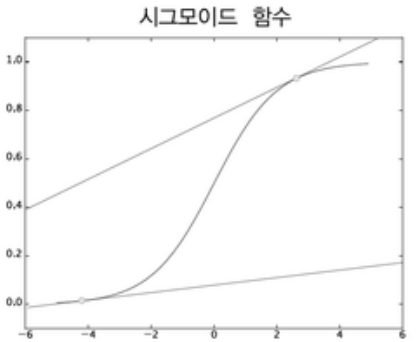

- **정확도를 지표로 삼지 않는 이유**
  - **정확도를 지표로 삼을 경우**
    - 미분 값이 대부분의 장소에서 0이 되어 매개변수를 갱신할 수 없다.
    - 정확도는 매개변수의 작은 변화에는 거의 반응을 보이지 않거나, 갑자기 변화한다.
    - 활성화 함수로 '계단 함수'가 아닌 '시그모이드 함수'를 사용하는 이유도 같다.
  - **손실함수를 사용한다면**
    - 계단함수는 대부분의 장소에서 기울기가 0 이지만, 시그모이드 함수의 기울기(접선)는 0이 아니다.
    - 계단 함수는 한순간만 변화를 일으키지만, 시그모이드 함수의 미분은 연속적으로 변한다.
    - 즉 시그모이드 함수의 미분은 어느 장소에서도 0이 되지 않는다.
    - 이는 신경망 학습에서 중요한 성질로, 기울기가 0이 되지 않는 덕분에 신경망이 올바르게 학습할 수 있다.

가중치의 조정(=최적화, Oprimizing)

- 가장 많이, 기본적으로 사용되는 가중치 조정 방법
  - 경사 하강법 (Gradient Descent)

초기값에 따라
최저점이
달라질 수 있다

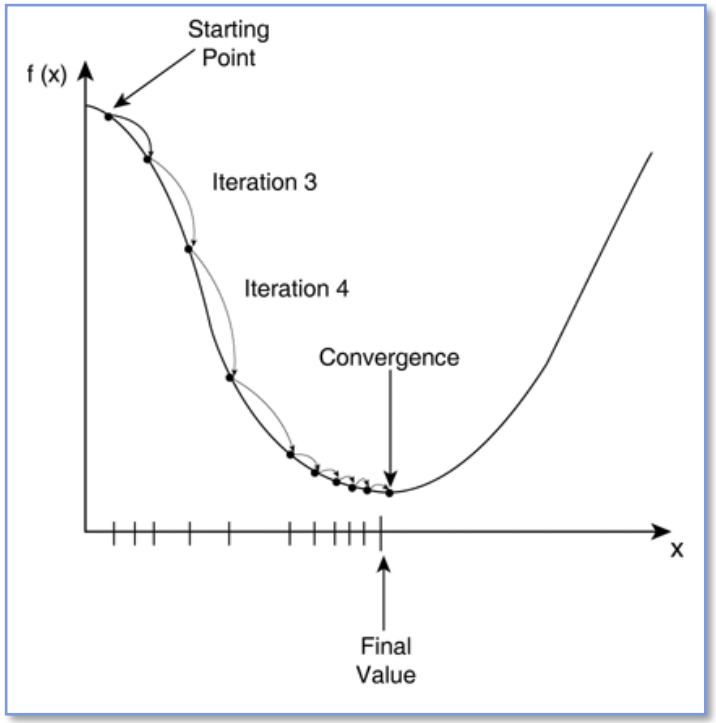

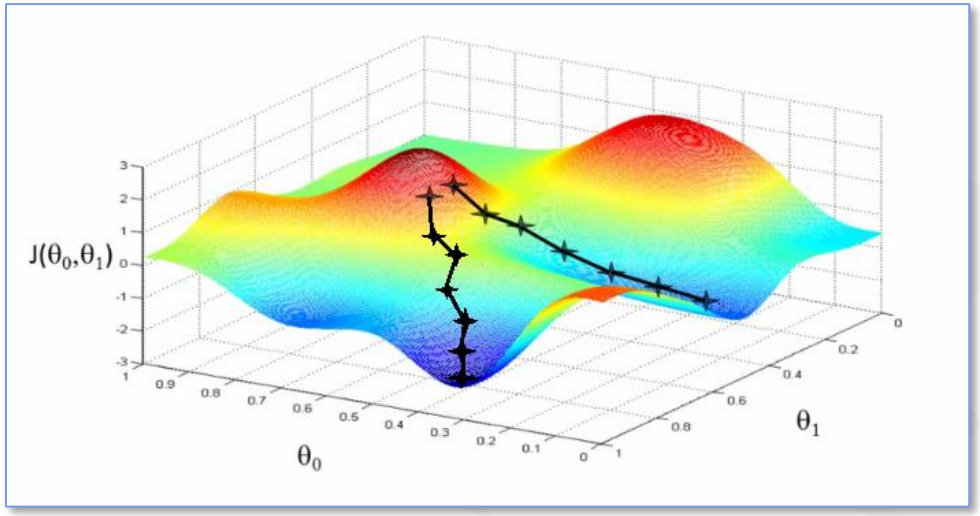

최저점은 하나가 아니다

이런 이유로...
같은 목적과 같은 데이터로 학습하더라도
모든 학습된 모델의 내부(가중치 집합)는 모두 다름

가중치의 조정(=최적화, Oprimizing)

- 그 외의 가중치 조정 방법들..
  - SGD, Momentum, AdaGrad, RMSprop, Adam 등

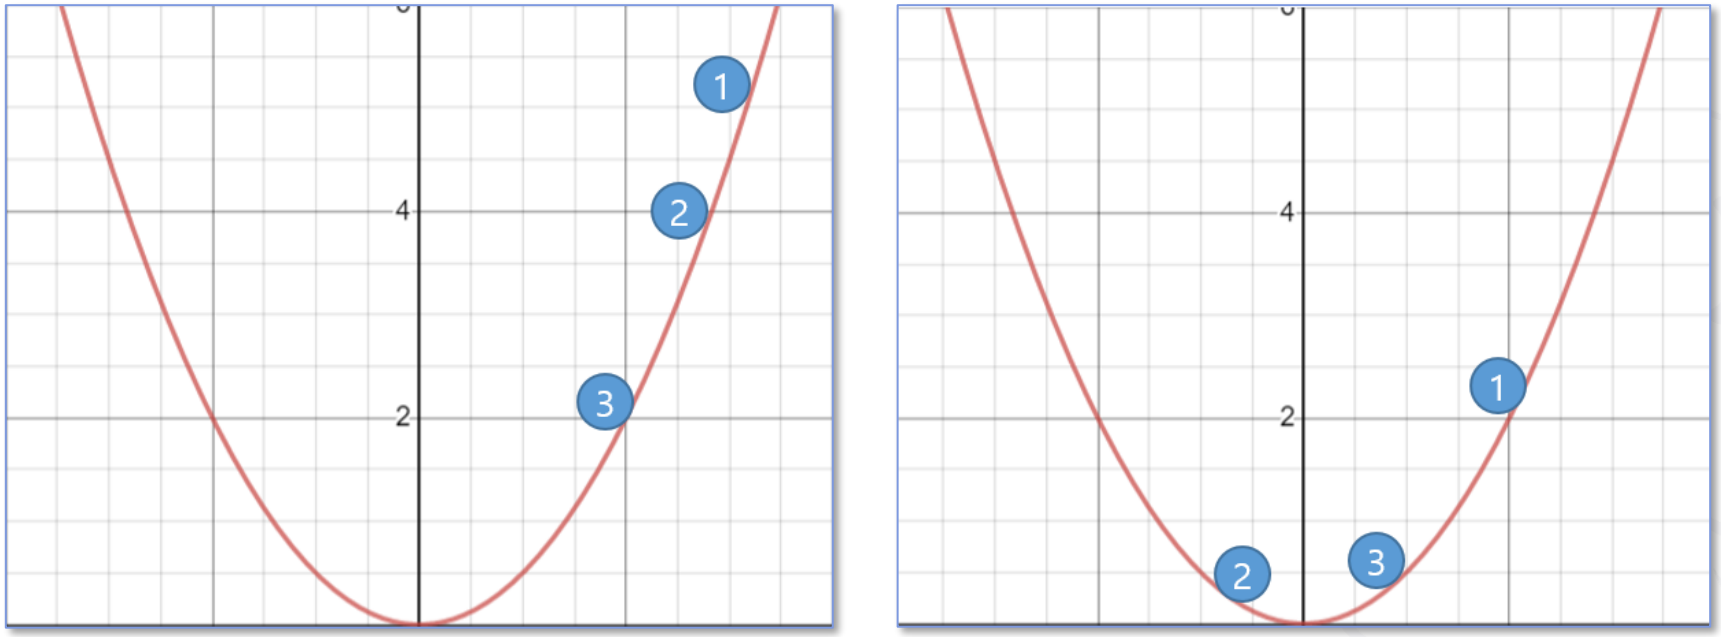

공이 굴러가듯이 움직인다

어떻게 굴러가는지, 어디에서 튀어 오르는지, 관성의 적용을 어떻게 받는지... 등

이런 특징들을 활용 또는 참고하여 새로운 방식을 고려할 수도 있다

가중치의 조정(=최적화, Oprimizing)

- **그 외의 가중치 조정 방법들..**

산 내려오는 작은 오솔길 잘 찾기(Optimizer)의 발달 계보

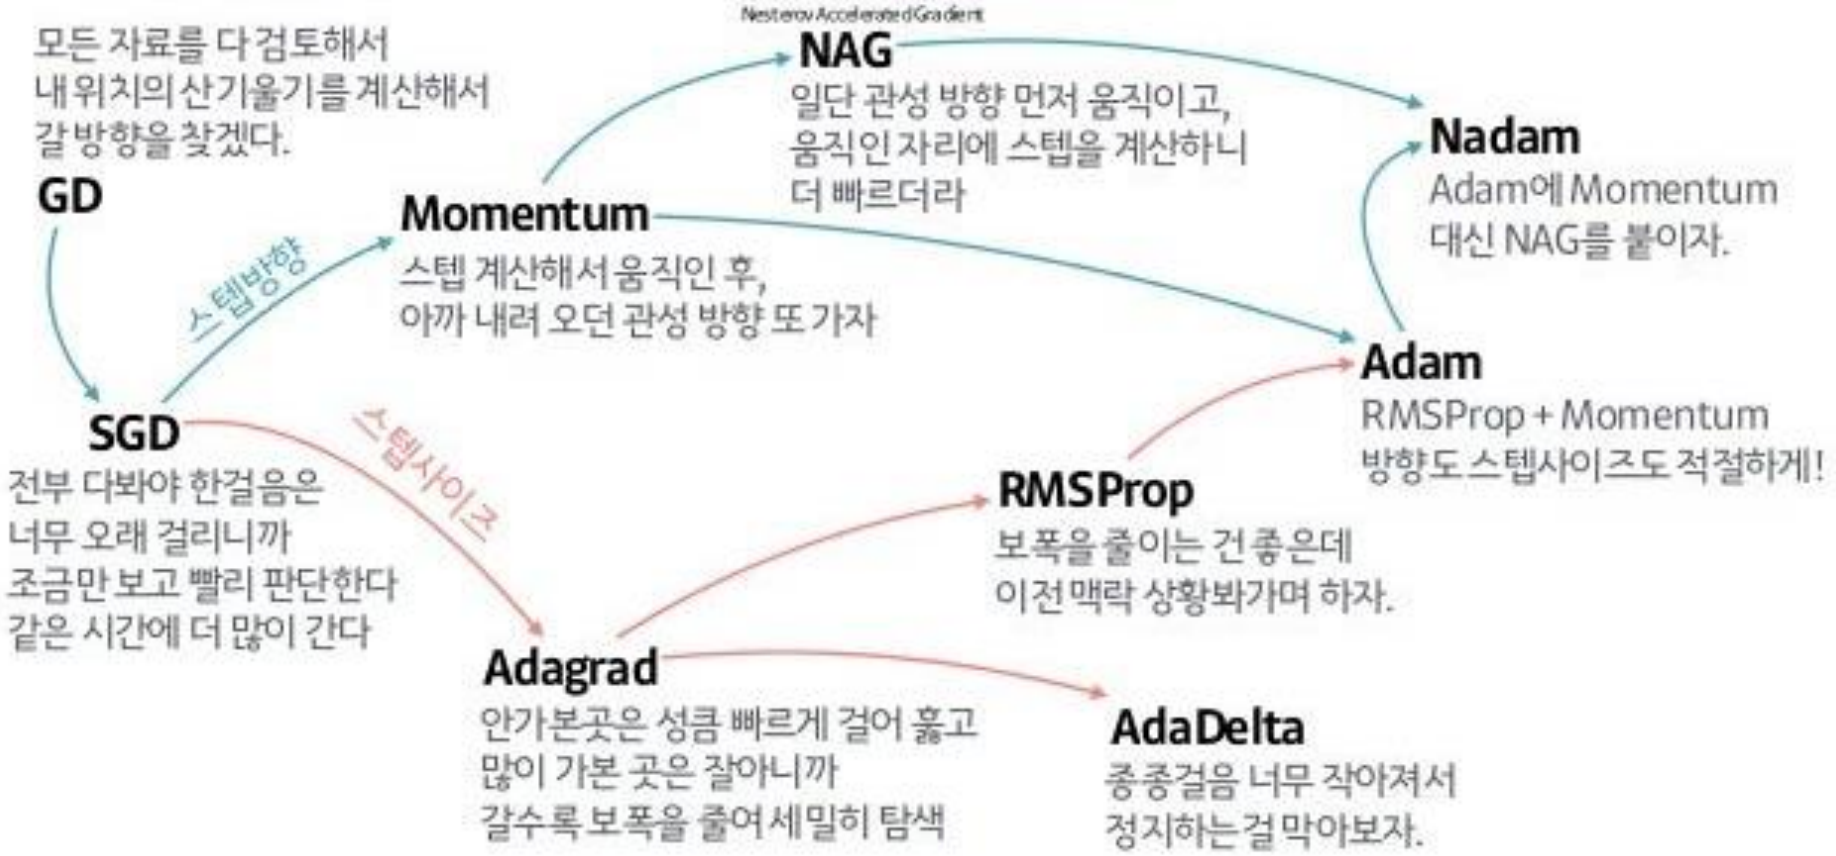

출처: 하용호, 자습해도 모르겠던 딥러닝, 머리속에 인스톨 시켜드립니다. (https://www.slideshare.net/yongho/ss-79607172)

가중치의 조정(=최적화, Oprimizing)

- 가중치 계산 방법으로 사용할 수 없는 것은?
  - 딥러닝 모델에서의 가중치 계산, 조정은 미분의 개념을 기반으로 움직임
  - 부드럽게 이어지지 않고 뾰족하거나 각진 형태로 인하여 미분이 불가능한 그래프의 형태를 가지는 계산 모델은 사용할 수 없음

과적합(Overfitting)

- 과적합(Overfitting)
  - 주어진 데이터로 학습을 너무 많이 하면 오히려 역효과!!
    - 학습에 입력된 데이터는 완벽에 가깝게 처리함
    - 학습에 입력되지 않은 데이터는 제대로 처리되지 않음
  - 원인: 잡음 데이터 (대부분)
    - 불필요한 정보가 많이 포함된 데이터로 학습이 반복됨에 따라 불필요한 정보가 분류의 기준에 포함되어 버리는 것이 원인

과적합(Overfitting)

- 과적합(Overfitting)의 해결 방안
  - 조기 종료
    - 적당한 선에서 학습을 종료시킴 → 데이터의 정규화와 관련
  - 정규화 (데이터를 일반화 시키기)
    - 필요한 신호는 학습하고 잡음은 제거하는 효과
    - 모델의 학습 난이도를 높임으로써 학습 데이터의 세부 사항(잡음 포함)에 대한 일반화를 활용하도록 하는 기법의 일부로 사용됨

과적합(Overfitting)

- **과적합(Overfitting)의 해결 방안**
  - **Drop Out**
    - 학습 중에 무작위로 선택한 뉴런을 0으로 설정

      → 군데군데 망의 연결고리를 잘라 내어 대형 신경망이 소형 신경망처럼 동작하게 만듦
    - 소형 신경망에서는 과적합이 거의 발생하지 않음 (표현능력이 협소하기 때문)
    - 대형 신경망(딥러닝 모델)을 Drop Out을 통해 소형 신경망처럼 동작하게 하여 과적합 발생률을 떨어뜨리는 방법

과적합(Overfitting)

- 앙상블(Ensemble)
  - 앙상블(Ensemble): 통일, 조화를 뜻하는 프랑스어. 음악에서 여러 악기들에 의한 협주를 의미함
    - 많은 수의 작은 악기소리가 조화를 이루어 더욱 더 웅장하고 아름다운 소리를 만들어 냄
    - 그런데 한 명의 아주 작은 실수는 다른 소리에 묻히기도 함
  - 기계학습에서의 앙상블: 많은 작은 모델이 모여 투표(Voting)를 통해 더욱 강력한 기능/결과를 도출함

    → 많은 모델이 함께 동작하기 때문에 소수의 일부 모델에서 예측을 잘못하더라도 일정수준 보정됨

    → 보다 일반화된 모델을 완성할 수 있음
  - 학습 방식에 따라 배깅(Bagging), 부스팅(Boosting), 스태킹(Stacking)으로 나눌 수 있음
    - 배깅(Bagging): Bootstrap Aggregating의 약자. 부트스트랩 (Boostrap)을 이용함. Random Forest 등
    - 부스팅(Boosting): 반복적으로 모델을 업데이트하면서 데이터셋 샘플에 대한 가중치를 부여함
    - 스태킹(Stacking): Weak learner들의 예측 결과를 바탕으로 meta learner로 학습시켜 최종 예측값을 결정함

결국 딥러닝이란?

- **엄밀하게 따지면 딥러닝이란…**
  - **다수의 노드에 적용되는 최적화 프로그램이다.**

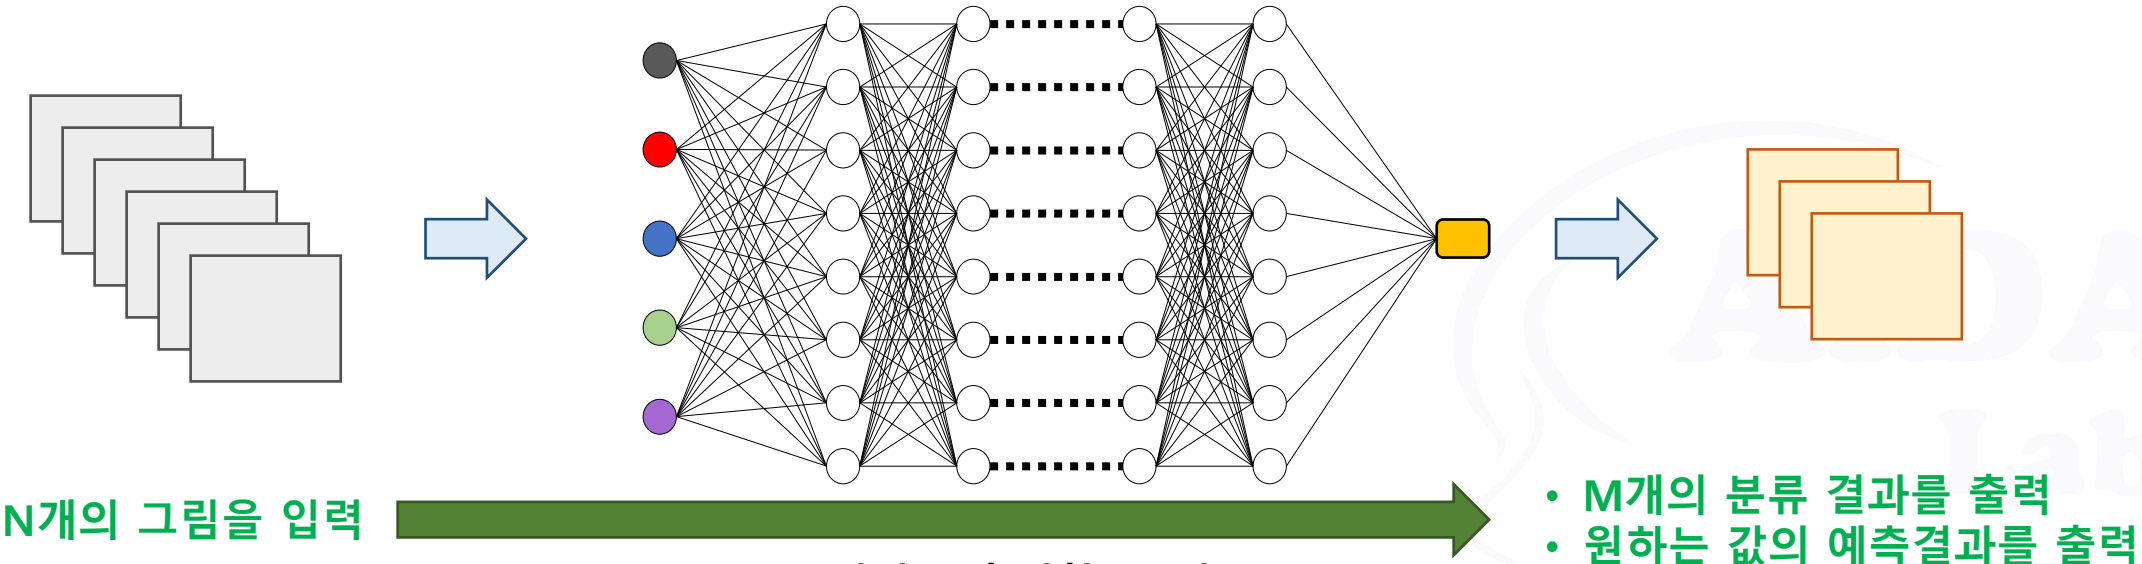

결과를 출력할 수 있도록

각 노드 사이의 경로에 대한 가중치를

조건을 모두 만족할 수 있는

값들의 집합으로 최적화 하는 프로그램

결국 딥러닝이란?

- 그렇다면 이것은 인공지능이 아니지 않나?
  - 애초에 인간의 두뇌 역시 다양한 입력의 결과를 올바르게 출력하기 위한 최적화 과정을 처리함
  - 많이 사용될 수록 굵어지고 민감해지는 각 신경세포 간의 시냅스 결합 강도를
  - 뉴런 사이의 가중치로 모델링하여 구현한 것일 뿐!!